

ドメイン一般化のための相互対照的な特徴の摂動

Chenming Li1 Daoan Zhang1 Wenjian Huang1 Jianguo Zhang1,2,*

1信頼自律システム研究所・コンピュータサイエンス学科
南方科学技術大学、深セン、中国

2Peng Cheng Laboratory、深セン、中国

12132339@mail.sustech.edu.cn、12032503@mail.sustech.edu.cn、{huangwj,zhangjg}@sustech.edu.cn、

抽象的な

ドメイン一般化 (DG) は、堅牢な概念を学習することを目的としています。ソース ドメインからのモデルを作成し、目に見えないターゲット ドメインをうまく一般化します。最近の研究は生成に焦点を当てていますディストリビューションを多様化するための新しいドメインのサンプルまたは機能ソースドメインを補完します。それでも、これらのアプローチは、さまざまなドメインから合成されたサンプルが意味の歪みを引き起こす可能性がありますという制限にほとんど対処できません。本稿では、オンライン一般階クロスを提案する。 — Contrasting Feature Perturbation (CCFP) フレームワーク 摂動された特徴を生成することでドメイン シフトをシミュレートします。モデル予測を正規化する際の潜在空間ドメインシフトに反対。以前の固定的な合成戦略とは異なり、学習可能な特徴の摂動と意味的一貫性の制約を備えたモジュールを設計します。

以前の研究とは対照的に、私たちの方法では何も使用しません。生成ベースのモデルまたはドメイン ラベル。私たちが実施するのは公正な比較のための厳格な評価プロトコルを使用した、標準の DomainBed ベンチマークでの広範な実験。包括的な実験により、私たちの方法が

以前の最先端の定量的パフォーマンスを上回ります。分析により、私たちのアプローチが配布外 (OOD) シナリオにおけるドメイン シフトの問題を軽減できることが示されています。<https://github.com/hackmebroo/CCFP>

1. はじめに

ディープ ニューラル ネットワークは、多くのコンピューター ビジョン タスクで目覚ましい成功を収めています[27,65]。これらモデルは iid 仮定[52]、つまりトレーニングに依存します。データとテスト データは同一かつ独立して配布されます。ただし、現実のシナリオでは、この仮定はドメインシフトの問題により、常に成り立つわけではありません[5]。たとえば、写真で訓練されたモデルにとっては困難ですスケッチに適応するため。

ドメイン アダプテーション (DA) 方法 [13,50,61] は、

*対応する著者。

の配布外 (OOD) 問題に対処するために策を講じました。ラベルのないターゲット データが利用可能な設定。それでも DA は既知のターゲット ドメインではうまく機能しますが、それでも失敗しますトレーニング中にターゲット ドメインにアクセスできない実際の状況では。ドメイン一般化 (DG) [59]の目的 このような問題に対処するために。ドメイン一般化の目標は、複数の異なるが関連するソース ドメイン (つまり、多様なトレーニング データセット) から一般化されたモデルを学習することです。同じラベル スペースを持つ) は、任意の目に見えないターゲット ドメインで適切にパフォーマンスを発揮できます。この目標を実現するには、最も深い学習モデルは平均損失を最小限に抑えるようにトレーニングされます経験的リスクとして知られるトレーニングセット全体にわたる最小化 (ERM) 原則[53]。ただし、ERMベースのネットワークはOOD シナリオに失敗することが証明されています [38,11,21,64]。一連の作業 [49,45,46] は、最悪の領域を最適化することでモデルの汎化能力を向上させます。によって作成される一連のドメイン候補に対するリスク画像レベルでサンプルを攪乱するか、生成ベースのモデル (VAE[25]または GAN[17])を使用して架空のサンプルを生成します。オフライン ベースでイメージ レベルでサンプルを作成し、ドメイン ファミリー全体にわたる最悪のケースを近似することによってパフォーマンスが向上したにもかかわらず、意味上の識別情報を失うことなく、入力空間に「架空の」サンプルを生成することは困難です[43]。さらに、オフラインの 2 段階データ摂動トレーニング手順は、どちらも生成ベースのトレーニングであるため、自明ではありません。

モデルを作成し、それらを推論して摂動サンプルを取得します。挑戦的なタスク。別の仕事は潜在的な機能を混乱させるスケーリングとシフトのパラメータを調整してspace[55, 70]インスタンスの正規化後。別の研究[32]はそれを拡張しますそして、特徴統計の摂動に関連する不確実性を利用します。ただし、これらの方法はすべて固定の摂動戦略 (線形補間またはランダム摂動)。合成サイズの特徴から元の特徴への領域の転送を制限します。さらに、インスタンスの正規化ベースの特徴の摂動は変化する可能性があります、

特定の中間特徴の情報ドメインに対しては、依然としてセマンティックの不変性を維持できません。

インスタンスの正規化により差別性が薄れる可能性があるため、アリタスクの目的に関連する情報[39]。特徴合成方法のパフォーマンスは不明な場合があります
意味上の矛盾のため[35]。

上で述べたように、データ摂動に基づく手法は入力空間に架空のサンプルを生成することがほとんどできず、特徴摂動ベースの手法は合成特徴の多様性を制限し、意味論的な一貫性を維持できません。この両方に対処するには

この問題を解決するために、最悪の場合の最適化目標に従って潜在空間でドメインを意識した適応特徴の摂動を強制し、クラス識別情報を保存するために意味の一貫性を明示的に制約することを提案します。

実際には、最悪の場合の DG 問題に対する要望は、ソース ドメインの分布と架空のターゲット ドメインの分布の間のドメインの不一致を最大化し、クラス識別特性を最小化することによって、現実的なドメイン シフトをシミュレートすることです。に

この目的のために、私たちは適応型オンライン 1 段階クロスを設計します。Contrasting Feature Perturbation (CCFP) フレームワーク。CCFP の図を図1に示します。
2 つのサブネットワークで構成され、1 つはのオンライン推定を表すオリジナルの特徴
もう 1 つはソースの分布に使用され、もう 1 つは特徴を混乱させるために使用されます。
潜在空間内で意味論的に不変の架空のターゲット分布を作成します。階級差別を維持するために
摂動された特徴の情報を利用して、2 つのサブネットワーク間の予測を正規化します。

私たちのフレームワークの重要なコンポーネントは、攪乱ごとの機能です。スタイルの研究分野で指摘されているように
transfer[10, 22]にあるように、特徴統計には主にドメイン固有に関する情報が含まれていますが、クラスの識別にはあまり関係がありません。これをもとに設計していきます
学習可能なドメイン摂動 (LDP) モジュール。
特徴の学習可能な摂動を生成して、
元のドメインからのドメインの転送。注意してください。
LDP は、学習可能なスケールリングおよびシフト パラメータのみを追加します。
ドメイン ラベルや追加の生成モデルを採用せずに特徴量統計を実現します。

CCFP のもう 1 つの重要なポイントは、ドメインの不一致。既存の学習対策との違い
最後の層のドメインの不一致[58, 51]、我々は、浅い層が存在するという観察と一致するように、中間の特徴からのドメインの不一致を測定することを提案します。
ネットワークの各層は、低レベルの機能 (色など) を学習します。
およびエッジ)は、よりドメインを認識しますが、セマンティックではありません。
関連性がある[60]。さらに、Gatys ら[15]グラムを見てください
潜在的な特徴の行列を使用して、文体のエンコードが可能
テキストチャやパターンなどの属性。これを原動力に、私たちは
を表す新しいグラム行列ベースの指標を開発する
中間アクティベーションからのドメイン固有の情報。私たちは、内部間の相違点を最大化します。

ドメインをシミュレートするための中間特徴のグラム行列シフト。
標準的な DG で CCFP の有効性を検証します
Domainbed と呼ばれるベンチマーク[18]。包括的な実験結果は、私たちの方法が以前の方法を超越、最先端のものであることを示しています。

要約すると、私たちの貢献は 3 つあります。

- 意味的一貫性を正則化しながら摂動特徴を生成できる、最悪の場合の領域汎化問題に対する新しいオンライン 1 段階クロスコントラスト特徴摂動フレームワーク (CCFP) を提案します。
- 学習可能なドメイン摂動 (LDP) を開発します。モジュールと、ドメインの不一致を測定するための効果的なドメイン認識グラム行列ベースのメトリクス、これらは DG にとって便利であり、上記に統合されています CCFP フレームワーク。さらに、私たちのアルゴリズムは、生成ベースのモデルとドメインを使用しないラベル。
- 包括的な実験により、私たちの方法が有効であることがわかりました。多様な DG で最先端のパフォーマンスを実現 厳格な評価プロトコルに基づくベンチマーク ドメインベッド[18]。

2. 関連作品

ドメイン一般化 (DG) は一般化を学習することを目的としています。任意の目に見えないターゲット ドメインをうまく一般化できる複数のソースドメインからの表現。たとえば、PACS データセット [30] では、タスクはカテゴリ関連の知識を抽出することであり、ドメインはさまざまなカテゴリに対応します。
アートペインティング、漫画、写真、スケッチなどの芸術的なスタイル。モデルは 4 つのデータセットのうち 3 つを使用してトレーニングし、使用します。
テストする残りのデータセット。さまざまな方法が提案されていますが、DG文献は大きく3つに分類できます
行: ドメイン不変表現の学習[51, 16, 37,36,57],メタ学習技術[47,3,9,29]およびデータ摂動ベースの方法[56,43,71]。私たちの仕事は一番最後の行に関連します。

データの摂動:入力におけるデータの摂動
空間は、偽の相関[46]を軽減し、モデルの一般化を改善するために多様な画像を作成できます。
ヴォルピラ[56]敵対的データの拡張を提案した
安定したトレーニングのためのアンサンブル モデルを学習しました。パイエット al.[2] OoD 一般化のための分解された特徴表現とセマンティック拡張アプローチ。チャオら[43]
それを拡張して、大規模なドメインメインの輸送を伴う「架空の」人口を作成しました。周ら[71]データ ジェネレーターを使用して、疑似新規ドメインからのデータを合成し、ソース ドメインを拡張しました。これらの方法とは異なり、私たちは
パータベーションの代わりに潜在空間特徴の摂動を提案します。

入力空間で生データを攪拌し、ドメインを必要としません
ラベルまたは生成ベースのモデル。

特徴の摂動:ほとんどのデータの摂動とは異なります。
入力空間で変換を採用するメソッド、いくつか
潜在空間内の摂動特徴にアプローチします。リーラ
al.[31]特徴の埋め込みにも混乱をもたらすことを示す
トレーニング中にガウス ノイズを使用すると、同等の結果が得られます
パフォーマンス。 Manifold Mixup [55]は、画像レベルから特徴レベルまで
線形補間を採用しています。最近の作品展示
2 つのインスタンスの特徴統計に対する線形補間
[70] はサンプルを合成してモデルの一般化を改善できます。ヌリエラ[41]
異なる統計をランダムに交換します
同じバッチからのサンプル。 [32]それを拡張して活用します
特徴の摂動に関連する不確実性。これら
方法は固定摂動戦略に基づいており、
セマンティクスを維持するための制約。私たちの仕事において、自民党は
モジュールは学習可能な摂動を生成して、
CCFP フレームワークはセマンティックの一貫性を明示的に保持できます。

3. 方法

3.1.一般的な配合

ドメインの一般化を分類で定式化します
入力特徴 $x \in X$ から予測ラベル $y \in Y$ までを設定します。モデルファミリー
 Θ とトレーニング データが与えられた場合
一部のディストリビューションから抜粋しました。目標はモデルを見つけることです
目に見えないターゲット分布までよく一般化する $\theta \in \Theta$
ブータル。 DG は次の問題として定式化できます。

— (1)

ここで、 $E[\cdot]$ は期待値、 $\ell(\cdot, \cdot)$ は損失関数です。
DG にとつての課題は、ターゲット ドメインの配布 P_{tar} が利用できないこ
とです。解決するための別のアプローチ
式(1)は、ソースドメインからのすべてのデータをマージするもので、
全体にわたるトレーニングエラーを最小限に抑えてモデルを学習します。
プールされたデータ。これは経験的リスク最小化 (ERM) 原則として知られて
います。

(2)

ここで、 P_{src} はトレーニング全体の経験的分布です。
データ。ERM ベースの手法は OOD シナリオに対する堅牢性に欠けていること
が明らかであるため [38,11]、多くの作業が行われています [28,20、
45,46]を利用して最悪の場合の問題として DG を定式化しました。
分散的に堅牢な最適化と敵対的トレーニング:

(3)

ここで、 $D(\cdot, \cdot)$ は確率分布空間上の距離計量です。式(3)の解は、次のことを達
成することを目的としています。

架空のターゲット分布 P が領域から距離 p 離れている間は、領域シフトに対
して良好なパフォーマンスが得られます。
ソース ドメインの配布 P_{src} 。式(3)を解くには、前の
研究では、入力空間でトレーニング サンプルを摂動するか、生成ベースのモデ
ルを使用してこれらに関してモデルを更新することによって、架空の分布 P を
作成することが期待されています。
架空の最悪の場合のターゲット分布。

ただし、画像レベルでサンプルを混乱させると、
モデルのトレーニングに有害なクラスの歪みを導入する
パフォーマンスの低下を引き起こす可能性があります。さらに、
オフラインの 2 段階のトレーニング手順にはかなりの時間がかかります
生成モデルのトレーニング以降の計算リソース
それを使用して追加のサンプルを取得することは、どちらも困難な作業です
[60,34]。

この点に関して、私たちはオンラインのワンステージクロスを提案します。
コントラスト特徴摂動 (CCFP) フレームワーク
(3.2 節)摂動表現分布 P を取得する
潜在空間での学習可能な特徴統計 (セクション 3.3) を使用
生成ベースのモデルは一切使用しません。さらに、攪乱ごとの特徴の意味的識
別情報を保存するために、明示的な意味的制約を利用して、

モデルが一貫した意味表現を予測するように促します。式 3 に従ってソース
ドメインの分布と架空のターゲット ドメインの分布を決定する必要があるた
め、デュアル ストリーム ネットワークを次のように利用します。

それを図1 に示します。
距離メトリックが重要であることは注目に値します。
最悪の場合の DG 問題。これは、ソース ドメインの分布と、

架空のターゲット ドメインの分布。理想的な目標は、
指標は、大規模な架空のターゲット分布を作成することです。
ソースディストリビューションとのドメインの不一致、および
意味的な識別情報を保持します。過去の作品
高レベルのセマンティクスの非類似性を直接高める
space[56] (通常は最後の層の出力)、したがって失敗します
意味的な識別情報を保存するため。目標を達成するために、潜在的な全体の非
類似性を高めるためのドメインを認識したグラム行列ベースのメトリクスを
提案します。

高レベル意味空間を除く空間(3.4節)。
さらに、意味上の識別情報をより適切に保存するために、正則化損失を利用し
て、ソースドメイン間の意味上の一貫性を明示的に制約します。

セクション 3.5の架空のターゲット ドメイン。

3.2.クロスコントラスト機能の摂動
フレームワーク (CCFP)

私たちの目標は現実的なドメインの変化をシミュレートすることなので、
潜在的な空間。ソース ドメインの分布を特定し、架空のターゲット ドメインの
分布を作成するには、次のようにします。
2 つのサブネットワークを使用して同じサブネットワークから特徴を抽出します
画像。図 1 に示すように、1 つは、
のオンライン推定を表すオリジナルの特徴
潜在空間におけるソース分布。もう 1 つは生成に使用されます。

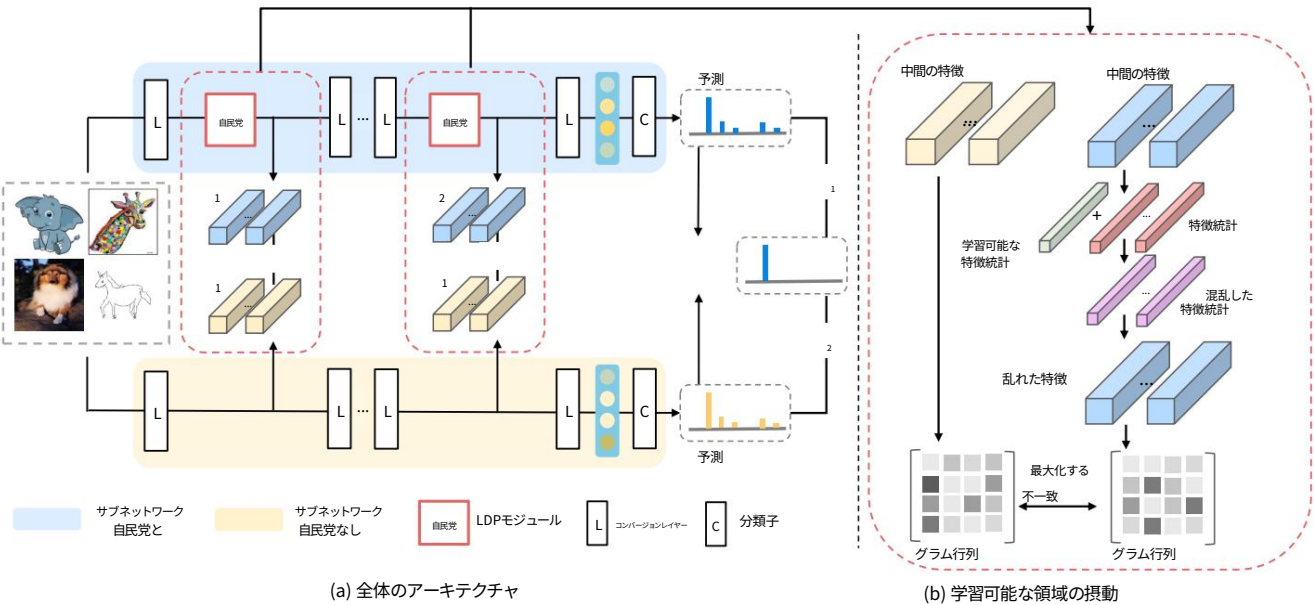


図 1 私たちが提案する CCFP の概要。私たちのフレームワークは 2 つのサブネットワークで構成されています。(a) 一番下のネットワークは事前にトレーニングされたネットワークです。バックボーンであり、最上位のネットワークは、LDP モジュール (赤いボックス) を備えた同じ事前トレーニング済みバックボーンです。2 つのサブネットワークには、同様のアーキテクチャ (LDP モジュールを除く) ですが、パラメータを共有しません。特徴摂動の手順と計算 Ldis を (b) に示します。

学習可能な領域摂動を使用して、架空のターゲット分布を表す摂動特徴を計算します。

中間層のモジュール。

実用的な観点から、選択するのは困難です

ドメインシフト p の適切な大きさ。この点に関して、式 3 をペナルティ パラメーター γ を伴う次のラグランジュ緩和とみなします。

ここで P^* は、潜在的なソース ドメインの分布です。

スペースと P^* は、潜在的な空間。双対再定式化 Eq.4 を利用すると、次のようになります。

を最大化する最小-最大最適化目標を取得します。

ソースディストリビューションとソースディストリビューション間のドメインの不一致ターゲットを最小化しながらの架空のターゲット分布危険。

min-max 最適化中、各反復は次のようになります。

2つのステップに分かれています。最大化ステップでは、バッチの画像が両方のサブネットワークに供給されて使用されます

Ldis で示されるドメイン不一致損失を計算します。

Eq.8 で詳しく説明しますが、LDP ブロックのパラメータのみが次のようになります。

この段階で更新されます。最小化ステップについても同じです

画像のバッチが再度モデルに供給され、分類損失 (クロスエントロピー損失) の計算に使用されます。

およびセマンティック一貫性の損失。Lsem で示されます。詳しくは、式 9.2 つのサブネットワークのすべてのパラメーターがこの段階で更新されます。

3.3.学習可能なドメイン摂動モジュール (LDP)

CCFP フレームワークの重要なポイントは、ドメインを認識した機能の摂動を作成する方法です。正規化後の中間特徴量のアフィン変換の摂動パラメータにより、その特性が変化する可能性があるため

これは主にドメイン固有の情報を指しますが、カテゴリ関連情報との関連性が低い[10,22]、

Huangら[22]アダプティブ インスタンス正規化 (AdaIN) を提案します。これは、入力特徴 x の特徴統計をスタイル イメージの特徴統計に置き換えます。

xsを使用してスタイルの転送を実現します。 $x \in \mathbb{R}$ とします

機能のバッチである場合、AdaIN は次のように定式化できます。

(5)

$$B \times CB \times C \text{ ただし } \mu(x) \in \mathbb{R} \text{ および } \sigma(x) \in \mathbb{R} \text{ は平均値であり、}$$

それぞれ標準偏差。ただし、DG シナリオでは、ターゲット ドメイン イメージの機能統計は利用できません。以前の研究[70、32]は線形補間を利用するか、特徴統計を多様化するための不確実性モデリングですが、どちらも、合成サイズのフィーチャからオリジナルのフィーチャへのドメインの転送を制限します。これに対処するために、学習可能なドメイン摂動 (LDP) モジュールを設計します (図 1 の赤いボックス) を使用して、摂動された中間特徴を生成します。

(6)

ここでは、学習可能なパラメータ γ と β を、特徴量の元のスケーリング $\sigma(x)$ 統計とシフト $\mu(x)$ 統計に追加するだけです。固定摂動戦略に基づく従来の研究とは異なり、LDP モジュールはドメインの不一致を拡大できます。

元のフィーチャと摂動されたフィーチャの間。

3.4.グラムベースのドメイン不一致メトリック

DG の最悪の場合の最適化の目的は、ソース分布から一定の距離内にある架空のターゲット分布に対してモデルのパフォーマンスを保証することです。

を可能にする DG の本質的な要望を考慮する
目に見えない領域までうまく一般化するモデル、理想
距離メトリックはドメイン固有であり、クラスを区別します。
不可知論的な。次のようなよく知られた観察[66]に触発されました。
浅い層はタスクとは無関係な低レベルの機能を学習し、効果的なドメインの不一致メトリクスを構築します。
浅い層に適用されます。具体的には、Gatys ら[15]
グラム行列が次のような文脈属性をエンコードできることを示しています。
タスクの目的とはあまり関係のないテキストチャやパターン
ただし、個々のドメイン情報を表すために使用できます。したがって、グラム行列ベースの指標を利用します。
ドメインの不一致を表現します。
具体的には、ネットワークを次のように表します。

$$L_{\text{dis}} = \sum_{i=1}^n \sum_{j=1}^n \left\| \frac{1}{B} \sum_{k=1}^B \text{go}(x_i) - \text{go}(x_j) \right\|^2$$
(7)

ここで g は分類子、 $f = f_n \circ f_{n-1} \circ \dots \circ f_1$ は特徴抽出器であり、 n は特徴抽出器の数を示します。
浅い層。私たちの方法では、グラムのセットを使用します
行列 $\{G_1, G_2, \dots, G_K\}$ をネットワーク内の一連の浅いレイ-、 f_k から抽出してドメイン-を記述します。
特定の特徴。ドメインの不一致による損失は、
次のように定式化されます。

$$L_{\text{dis}} = \sum_{i=1}^n \sum_{j=1}^n \left\| \frac{1}{B} \sum_{k=1}^B \text{go}(x_i) - \text{go}(x_j) \right\|^2$$
(8)

ここで、 fo と fp はそれぞれ 2 つの特徴抽出器 (オリジナルとタープごと) です。 K は浅い層の数です。
損失 L_{dis} を計算します。 $G(\cdot)$ はグラム行列です。
 $\|\cdot\|_F$ はフロベニウス ノルムを示します。

3.5.明示的なセマンティック一貫性制約

意味の一貫性をより良く保つために、最終的な分類子の予測間の L_2 ノルムを最小限に抑えます。
2 つのサブネットワークの。セマンティックな一貫性が失われる可能性があるのは、
次のように定式化されます。

$$L_{\text{sem}} = \sum_{i=1}^n \sum_{j=1}^n \left\| \frac{1}{B} \sum_{k=1}^B \text{go}(x_i) - \text{go}(x_j) \right\|^2$$
(9)

Here go と gpl は 2 つの分類子 (元の分類子と摂動された分類子) です。それぞれ)。最終的な損失は次のように計算されます。

$$L_{\text{total}} = L_{\text{dis}} + L_{\text{sem}}$$
(10)

アルゴリズム 1 : クロス コントラスト フィーチャの摂動

入力: ひずみ= {(xi , yi)} n
 i=1、
 バッチサイズ B、学習

レート η、アダム オプティマイザー、初期λdis、 λsem

初期値: CCFP のパラメータ、つまりパラメータθ0、 θ1、 0、

1、 (yk, βk; k= 1 ⋅ ⋅ ⋅ K) 特徴抽出器fo, fp,

分類子go、 gp、LDP モジュール P
 1、 P2...PK
 (Kさんは

式 8 で定義)。

繰り返す

最小化段階:

i = 1 の場合、 ⋅ ⋅ ⋅ 、 B はする

Lcls1 i = ℓ(go(fo(xi)), yi)

Lcls2i = ℓ(gp(fp(xi)), yi)

Lsem = λsem||fo(xi) − fp(xi)||2 2

終わります

θ0、 0 ← アダム(
 1/B
 B
 i=1
 Lcls1 + Lsem、 θ0、 0、 η)

θ1、 1、 γk、 βk ← アダム(
 1/B
 B
 i=1
 Lcls2 + Lsem、 θ1、 1、

γk、 βk、 η)

最大化ステージ:

i = 1 の場合、 ⋅ ⋅ ⋅ 、 B はする

Ldis = λdis
 K
 k=1
 ||G(f
 k
 (xi))−G(f
 k
 p
 (P
 k
 (xi))))||F

終わります

γk、 βk ← アダム(
 1/B
 B
 i=1
 Lj
 j=1
 すべて、 γk、 βk、 η)

θ0、 θ1、 0、 1 が収束するまで

λdis と λsem は、強度を制御するために使用されます。
ドメイン不一致損失 Ldis と意味的一貫性
ロス Lsem。
最適化アルゴリズムはアルゴリズム 3.5 で設計されています。
推論中は、サブネットワーク (最上位のネットワーク) のみを使用します。
図 1 のネットワーク) は摂動から学習されます。
さまざまな潜在的機能がドメインのシフトを軽減するのに役立つため、最終結果を予測するための機能が追加されます。さらに自民党は、
モジュールは、モデルの崩壊を引き起こす可能性がある正規化統計の変動を防ぐためにも使用されます。統計のシフトはトレーニング中にランダムに LDP を適用することと軽減できますが、LDP モジュールは次のことを行うことができます。

テスト時の増強テクノロジーとしても使用され、
パフォーマンスについては、付録で説明します。

4. 実験

4.1.ドメインベッドベンチマーク

に関する総合的な実験を行っています。
DomainBed ベンチマーク[18]。DomainBed に含まれるもの
7 つのマルチドメイン画像分類タスク: 色付き
MNIST[1]、回転 MNIST[16]、PACS[30]、VLCS[12]、
Office-Home[54]、Terra Incognita[4]、および DomainNet[42]。
Colored MNIST[1] は、次元 (2,28,28) と 2 の 70,000 個の例で構成される MNIST の変形です。
クラス。データセットには、色付きのデジタルの素のセットが含まれています。

アルゴリズム										CMNIST	RMNIST	VLCS	PACS	OfficeHome	TerraInc	DomainNet	Avg	
ERM[52]	51.5 ± 0.1	98.0 ± 0.0	77.5 ± 0.4	85.5 ± 0.2	52.0 ± 0.3	66.5 ± 0.3	46.1 ± 1.8	40.9 ± 0.1	33.9	66.6								
IRM[1]	0.1	97.7 ± 0.1	78.5 ± 0.5	83.5 ± 0.8	GroupDRO[46]	64.3 ± 2.2	47.6 ± 0.8	± 2.8		65.4								
52.1 ± 0.0	98.0 ± 0.0	76.7 ± 0.6	84.4 ± 0.8	ミックスアップ[62]	52.1 ± 0.2	66.0 ± 0.7	43.2 ± 1.1	33.3 ± 0.2		64.8								
98.0 ± 0.1	77.4 ± 0.6	84.6 ± 0.6	MLDG[29]	51.5 ± 0.1	97.9 ± 0.0	77.2 ± 0.3	68.1 ± 0.3	47.9 ± 0.8	39.2 ± 0.1	66.7								
0.4	84.9 ± 1.0	コーラル[50]	51.5 ± 0.1	98.0 ± 0.1	78.8 ± 0.6	86.2 ± 0.3	66.8 ± 0.6	47.7 ± 0.9	41.2 ± 0.1	66.7								
MMD[33]	51.5 ± 0.2	97.9 ± 0.0	77.5 ± 0.9	84.6 ± 0.5	DANN[14]	51.5 ± 0.1	68.7 ± 0.3	47.6 ± 1.0	41.5 ± 0.1	67.5								
0.2	97.8 ± 0.1	78.6 ± 0.4	83.6 ± 0.4	CDANN[33]	51.7 ± 0.1	97.9 ± 0.1	66.3 ± 0.1	42.2 ± 1.6	23.4 ± 9.5	63.3								
77.5 ± 0.1	82.6 ± 0.9	51.4 ± 0.1	97.9 ± 0.0	77.2 ± 0.4	84.6 ± 0.5	51.7 ± 0.1	65.9 ± 0.6	46.7 ± 0.5	38.3 ± 0.1	66.1								
0.0	98.0 ± 0.0	77.8 ± 0.5	86.3 ± 0.2	56.2 ± 0.2	98.2 ± 0.1	77.6 ± 0.3	65.8 ± 1.3	45.8 ± 1.6	38.3 ± 0.3	65.6								
MTL[6]		± 0.4	51.8 ± 0.1	97.9 ± 0.1	78.3 ± 0.2	84.9 ± 0.6	66.4 ± 0.5	45.6 ± 1.2	40.6 ± 0.1	66.2								
サグネット[40]		51.7 ± 0.2	97.6 ± 0.1	77.1 ± 0.5	85.2 ± 0.9		68.1 ± 0.1	48.6 ± 1.0	40.3 ± 0.1	67.2								
アーム[67]							64.8 ± 0.3	45.5 ± 0.3	35.5 ± 0.2	66.1								
V-REx[26]							66.4 ± 0.6	46.4 ± 0.6	33.6 ± 2.9	65.6								
RSC[23]							65.5 ± 0.9	46.6 ± 1.0	38.9 ± 0.5	66.1								
AND マスク [24]	51.3 ± 0.2	97.6 ± 0.1	78.1 ± 0.9	84.4 ± 0.9	SAND マスク	65.6 ± 0.4	44.6 ± 0.3	37.2 ± 0.6	42.9	65.5								
[24]	51.8 ± 0.2	97.4 ± 0.1	77.4 ± 0.2	84.6 ± 0.9	51.6 ± 0.1	98.0 ± 0.0	77.8 ± 0.1	± 1.7	32.1 ± 0.6	45.1 ± 1.3	64.6							
魚[48]		± 0.3	85.5 ± 0.3	52.0 ± 0.2	97.8 ± 0.0	77.8 ± 0.1	68.6 ± 0.4	42.7 ± 0.2	47.4 ± 1.6	41.7	67.1							
フィッシャー[44]		85.5 ± 0.4					67.8 ± 0.1	± 0.0			67.1							
CCFP (当社)	51.9 ± 0.1	97.8 ± 0.1	78.9 ± 0.3	86.6 ± 0.2			68.9 ± 0.1	48.6 ± 0.4	41.2 ± 0.0	67.7								

表 1. トレーニング ドメイン モデルの選択を伴う DomainBed.最良の結果を太字で強調しました。

ここで、ドメイン $d \in \{90\%, 80\%, 10\%\}$ は相関関係です。ドメイン全体での色とラベルの強さ。回転した MNIST[16] は、次元 (1,28,28) の 70,000 個のサンプルと 10 個のクラスで構成される MNIST のバリエーションです。データセット d 度回転された数字が含まれます。ここで、ドメイン $d \in \{0, 15, 30, 45, 60, 75\}$ 。PACS[30]にはドメイン $d \in \{\text{art, 漫画, 写真, スケッチ}\}$ 9,991 の寸法例 (3,224,224) と 7 つのクラス。VLCS[12] には、ドメイン $d \in \{\text{Caltech101, LabelMe, SUN09, VOC2007}\}$ が含まれています。10,729 の次元 (3,224,224) と 5 つのクラスの例。Office-Home[54] には、次元 (3, 224, 224) の 15,588 個の例を持つドメイン $d \in \{\text{atr, Clipart, product, real}\}$ が含まれています。そして65クラス。Terra Incognita[4]には写真が含まれています $d \in$ の位置でカメラトラップによって撮影された野生動物の数 {L100,L38,L43,L46} 24,788 個の次元 (3,224,224) の例と 10 個のクラス。DomainNet[42]には以下が含まれます
ドメイン $d \in \{\text{クリップアート, インフォグラフィック, 絵画, クイックドロー, リアル, スケッチ}\}$ 586,575 の寸法例 (3,224,224) として345クラス。

公平な比較のために、DomainBed ベンチマーク[18] データセットの分割、モデルに関する評価プロトコルを提示します。検証セットの選択とハイパーパラメータ (HP) 検索については、以下で詳しく説明します。

データセットの分割。ソースドメインのデータが分割される トレーニングサブセット (80%) と検証サブセット (20%) に分割 (トレーニング ドメイン検証セット モデルの選択で使用されます)。ターゲット ドメインからのデータはテスト用のサブセットに分割されます (80%) および検証サブセット (20%) (テストドメインで使用) 検証セットモデルの選択)。私たちは経験全体を繰り返します。

異なるシードを使用して 3 回実行し、平均を報告します すべての繰り返しに対する標準誤差。
モデルの選択方法。 [18]には 3 つのモデル選択方法があります。
(i) トレーニング ドメイン検証セット。
(ii) リープワンアウト相互検証。 (iii) テストドメイン検証セット (oracle)。 トレーニングドメインモデルを選択します
トレーニングとテストの例が続くことを前提とした選択
同様の分布。検証セット内で最もパフォーマンスの高いモデルが最終モデルとして選択され、そのテスト ドメインが選択されます。
パフォーマンスは最終パフォーマンスとして報告されます。 Oracle モデルの選択結果を付録に示します。

モデルアーキテクチャ。 DomainBed に続いて、使用します バックボーンとしてのConv-Net (詳細は [18] の付録 D.1) Colored MNIST と Rotated MNIST には ResNet- 50[19]を使用し、残りのデータセットには ResNet-50[19] を使用します。分類子には、1 つの線形レイヤー。最初のモジュールの後にLDPモジュールを挿入します。Conv、Max Pooling、および 1、2、3 番目の ConvBlock、およびさまざまな効果についてのアブレーション研究をさらに実行します。挿入された位置。 Conv-Net をバックボーンとして使用する場合、最初のモジュールの後の位置にLDPモジュールを挿入します。3 つのバッチ正規化レイヤー。

ハイパーパラメータ (HP) 検索。ランダム検索を実行します で与えられるハイパーパラメータ分布に対する 20 回の試行のうち、ドメインベッド。私たちの CCFP は 2 つの追加ハイパーパラメータ λ_{spe} と λ_{sem} に依存しており、検索範囲を次のように設定します。どちらも [0.1, 10] として、範囲の詳細を示します。ハイパーパラメータ検索については付録で説明します。

実装の詳細。 PyTorch の DomainBed のコードベースを使用して アルゴリズムを実装します。

ImageNet[8] で事前トレーニングされた ResNet-50と微調整各データセットについて。評価設定は以下に従っていることに注意してください。DomainBed[18] によって与えられた標準評価プロトコル。

4.2.結果

ドメイン汎化手法との比較
Domainbed ベンチマークで。包括的な実験により、CCFP が優れたパフォーマンスを達成することが示されていますほとんどのベンチマーク データセットで以前の方法よりも優れており、3 つのデータセットで同等のパフォーマンスが得られます。7 つのデータセットのうち、表1は、次の結果をまとめたものです。

トレーニング ドメイン モデルの選択を使用した DomainBed
方法。当社の CCFP は、これまでのすべてのアプローチを上回るパフォーマンスを発揮します平均した結果について。

CCFP の一般化をさらに検証するために、一般的に使用される別のベースラインの下で実験を実施します。独自のモデル選択メカニズムであるSWAD[7]をバックボーンとしています。公平な比較のために、要約のみを行いますSWADに基づいた手法。性能比較
SWAD を採用した他の既存のアプローチとの関係を表2～4に示します。当社の CCFP は、すべての実験において、以前の最良の結果と比べて大幅なパフォーマンス向上を達成しました。

アルゴリズムAC	PR 平均
スワッド[7]	66.1 57.7 78.4 80.2 70.6
PCL[63]	67.3 59.9 78.7 80.7 71.6
CCFP（当社）	68.0 58.6 79.7 81.9 72.1

表 2. SWAD ベースの最先端の手法との比較
OfficeHome ベンチマークで。A: アート、C: クリップアート、P: 製品、R: リアル、平均: 平均。

アルゴリズム CLSV 平均
スワッド[7] 98.8 63.3 75.3 79.2 79.1
PCL[63] 99.0 63.6 73.8 75.6 78.0
CCFP（当社） 98.9 64.1 74.9 79.9 79.4

表 3. SWAD ベースの最先端の手法との比較
VLCSベンチマークで。C: Caltech101、L: LabelMe、S: SUN09、V: VOC2007、平均: 平均。

アルゴリズム	L100	L38	L43	L46	平均
スワッド[7]	55.4	44.9	59.7	39.9	50.0
PCL[63]	58.7	46.3	60.0	43.6	52.1
CCFP（当社）	59.9	47.6	60.8	43.8	53.0

表 4. SWAD ベースの最先端の手法との比較
TerraIncognita ベンチマークで。L100: 位置100、L38: 位置38、L43: 場所 43、L46: 場所 46、平均: 平均。

以前の特徴摂動との比較
方法。learn を使用してパフォーマンスの向上を明らかにするには、

特徴統計量を摂動するパラメータを利用できるため、以前の 2 つの特徴摂動法 Mixstyle[70]およびDSU[32]と比較する実験を実施しました。両方ともなので、彼らは独自の実験設定を使用します。公平な比較のために、DomainBed 実験での結果を再実行します。基準。表5は、当社の CCFP が以前の特徴摂動手法と比較してパフォーマンスの大幅な向上を達成していることを示しています。詳細な実験結果付録に示されています。

アルゴリズム ACPS 平均				
ERM	81.6	78.7	95.5	78.7 83.6
ミックススタイル[70]	84.0	79.9	94.3	81.6 84.9
DSU[32]	81.9	79.6	95.0	79.6 84.1
CCFP（当社）	87.5	81.3	96.4	81.4 86.6

表 5. 以前の特徴摂動手法との比較
PACSベンチマークで。PACS ベンチマークにおける SWAD ベースの最先端の手法との比較。

5. アブレーション研究

明示的なセマンティック正則化の効果。セマンティック正則化の有効性を検証するために、Eq.10の意味の一貫性の損失を使用せずに実験を実行します。表6は、セマンティック正則化によりほとんどのターゲット ドメインでパフォーマンスの向上が達成できることを示しています。そして平均的な精度。特に次のことがわかります。セマンティック正則化を行わなくても、私たちの方法は依然として ERM を大幅に上回ることができます。

アルゴリズム	ACPS 平均
ERM	81.6 78.7 95.5 78.7 83.6
CCFP(なし) Lsem	83.6 83.9 96.4 80.3 86.0
CCFP（当社）	87.5 81.3 96.4 81.4 86.6

表 6. PACS でLsemを使用しない場合の結果との比較
基準。

潜在空間内の特徴を摂動させた後、意味の一貫性を正規化するための本質をさらに検証するには、以前の機能にセマンティックな正則化を適用します摂動法。Mixstyle と DSU の両方が使用することに注意してください。摂動された特徴を生成する単一のネットワーク。Eq.10のLsemを計算できません。これに対処するために、私たちはCCFP フレームワークに 2 つのメソッドを実装します。私たちのアプローチと同様に、1 つのサブネットワークを使用して元の機能を使用し、他のサブネットワークを使用して生成するMixstyle と DSU 機能を使用した摂動特徴摂動法。さらに、一貫性を制約します2 つのサブネットワークの予測の間。その間推論では、摂動されたサブネットワークのみを使用して、私たちのアプローチと同じ最終予測を生成します。Mixstyle と DSU はノンパラメトリックであるため、

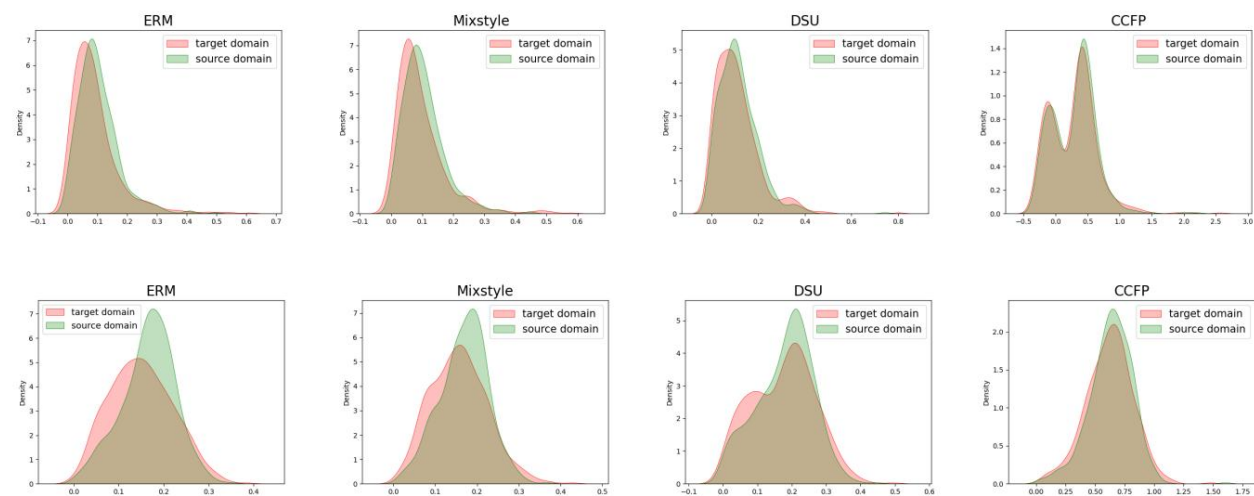


図 2. 位置 3 の特徴統計量の視覚化。上の生は平均統計量、下の生は標準統計量です。ERM、Mixstyle、DSU、および CCFP を使用して PACS データセットで実験を実施します。

この実験ではEq.10 のLdisを削除します。表7に示します
デュアル ストリーム アーキテクチャと明示的なセマンティクス
一貫性の正則化により、パフォーマンスが大幅に向上します (Mixstyle では
0.3%、DSU では 1.4%)。

アルゴリズム ACPS 平均	
ミックススタイル[70]	84.0 79.9 94.3 81.6 84.9
ミックススタイル (デュアル)	84.6 80.3 96.5 79.5 85.2
DSU[32]	81.9 79.6 95.0 79.6 84.1
DSU (デュアル)	86.3 79.4 94.6 81.7 85.5
CCFP (当社)	87.5 81.3 96.4 81.4 86.6

表 7. PACS ベンチマークにおける以前の機能摂動手法の追加のセマンティック一貫性の検証。

自民党が挿入したポジションの影響。CCFP では、
セットからの中間特徴のグラム行列のセット
層の数 {f¹, ..., f_k} を使用してドメイン固有の情報を記述します。
特徴[69,68]。挿入したLDPの効果を検証するには
位置を指定する場合、最初の位置に続いて ResNet の位置に名前を付けます。
Conv、Max Pooling、および 1,2,3 番目の ConvBlock を 1,2,3,4,5 として指定
それぞれ、および異なる挿入に対するLDPの効果
ポジションはそれに応じて評価されます。データセット PACS と OfficeHome
をデフォルトで実験します。

DomainBed によって指定されるハイパーパラメータ、表8は次のことを示しています。
より多くのLDPモジュールを挿入すると、比較的高い出力が得られます
分類の精度。したがって、LDP モジュールを接続します
主な実験では 5 つの位置すべてに配置します。
CCFPによる可視化解析。私たちのことを確認するために、
CCFP はドメイン シフト現象を軽減できるため、アートを選択した PACS デ
ータセットで実験を実施します。
ペイントをターゲット ドメインとして、残りをソース ドメインとして描画しま
す。位置 4 から中間の特徴をキャプチャします。
特徴統計量の変化を調べます。図2にその機能を示します。

ポジション	1-3 2-4 3-5 1-5 ERM	
PACS	85.3 84.8 85.4 86.6 83.6	
オフィスホーム	68.4 68.5 68.3 68.9 64.5	

表 8. PACS および Off-iceHome ベンチマークに対するさまざまな挿入位置の影響。

ソースドメインとターゲットからの統計の分布
ERM、Mixstyle、DSU、および当社の CCFP に基づくドメイン。
公平な比較のために、ERM の結果を再現します。
同じ固定ステップの Mixstyle、DSU、および CCFP (5,000
ステップ (Do-mainBed によって指定されるデフォルト値と同じ) であり、最
後のチェックポイントのみを考慮します。それは
私たちの CCFP が明らかにドメインを軽減できることが示されました。
ERM と比較してソース ドメイン機能とターゲット ドメイン機能の間でシフ
トし、Mixstyle や DSU を上回ります。結果
私たちの方法がドメインシフトに対抗できることを示しています。

6. 結論

この論文では、シンプルだが効率的なクロスコントラスト特徴摂動フレー
ムワークを提案します。以前とは異なり
機能する場合、私たちの方法は生成ベースのモデルを使用しません。
ドメインラベル。私たちのアプローチは、

意味上の一貫性を維持しながら元の機能を維持し、
モデルがドメインのシフトに対して一貫した意味表現を予測することを奨励
します。実験が示すのは
DomainBed ベンチマークでは、私たちの方法が以前の最先端のものよりも優れたパ
フォーマンスを発揮することがわかりました。

7. 謝辞

この研究は、National Key Research と
中国発展計画 (2021YFF1200800)

参考文献

[1] マーティン・アルジョフスキー、レオン・ボッター、イシャーン・グラジャニ、デビッド・ロペスパス。不変リスクの最小化。統計,1050:27,2020。

[2] Haoyue Bai,Rui Sun,Lanqing Hon,Fengwei Zhou、葉南洋、葉ハン・ジア、SHゲイリー・チャン、李正国。Decaug: 分解による分布外の一般化
特徴表現とセマンティック拡張。人工知能に関する AAAI 会議の議事録では、35 巻,6705 ~ 6713 ページ,2021 年。

[3] ヨゲシュ・バラジ、スワミ・サンカラナヤナン、ラマ・チェルラッパ。Metareg: メタ正則化を使用したドメインの一般化に向けて。神経情報処理の進歩システム,31,2018。

[4] サラ・ピアリー、グラント・ヴァン・ホーン、ピエトロ・ペローナ。認識インコグニータで。欧州コンピューター ビジョン会議 (ECCV) の議事録,456 ~ 473 ページ,2018 年。

[5] シャイ・ベン・デイヴィッド、ジョン・ブリッツァー、コビー・クラマー、アレックス・クレザ、フェルナンド・ペレイラ、ジェニファ・ウォートマン・ヴォーン。さまざまな領域から学ぶ理論。機械学習,79(1):151-175,2010。

[6] ジル・ブランチャード、アニケット・アナンド・デシュムク、ウルン・ドーガン、ゲミン・リー、クレイトン・スコット。によるドメインの一般化
限界転移学習。機械学習ジャーナル研究,22(1):46-100,2021。

[7] チャ・ジュンボム、チョン・サンヒョク、イ・ギョンジェ、チョ・ハンチョル、パク・スンヒョン、イ・ユンソン、ソンレ公園。Swad: フラットな最小値を求めることによるドメインの一般化。神経情報処理システムの進歩,34:22405-22418,2021。

[8] Jia Deng,Wei Dong,Richard Socher,Li-Jia Li,Kai Li、そして李菲菲。Imagenet: 大規模な階層イメージデータベース。2009 年のコンピューター ビジョンに関する IEEE カンファレンスとパターン認識,248 ~ 255 ページ。いえいえ,2009年。

[9] Qi Dou,ダニエル・コエーリョ・デ・カストロ、コンスタンティノス・カムニツァス、そしてベン・グロッカー。モデルに依存しないドメインの一般化
意味的特徴の学習。神経情報処理システムの進歩,32,2019。

[10] ヴァンサン・デュムラン、ジョナサン・シュレンズ、マンジュナート・クドゥルルール。芸術的なスタイルの学習された表現。arXiv プレプリント arXiv:1610.07629,2016。

[11] シアン・イーストウッド、アレクサンダー・ロビー、シャシャンク・シン、ジュリアス・フォン・クーゲルゲン、ハメド・ハッサーニ、ジョージ・J・ババス、ベルンハルト・シヨルコップ。分位リスクの最小化による可能性のあるドメインの一般化。arXiv プレプリント arXiv:2207.09944,2022。

[12] チェン・ファン、イエ・シュウ、ダニエル・N・ロックモア。公平なメトリック学習: 複数のデータセットとウェブの利用について
偏見を和らげるための画像。コンピューター ビジョンに関する IEEE 国際会議議事録,1657 ~ 1664 ページ、2013年。

[13] ヤロスラフ・ガーニンとヴィクトル・レンビツキー。監視されていないドメイン
バックプロパゲーションによる適応。国際会議で機械学習について,1180 ~ 1189 ページ。PMLR,2015 年。

[14] ヤロスラフ・ガーニン、エフゲニヤ・ウスティノワ、ハナ・アジャカン、バスカル・ジェルマン、ウーゴ・ラロシェル、フランソワ・ラヴィオレット、マリオマルシャンとヴィクトル・レンビツキー。ニューラル ネットワークのドメイン敵対的トレーニング。機械学習のジャーナル研究,17(1):2096-2030,2016。

[15] レオン・ゲイティス、アレクサンダー・S・エッカー、マティアス・ベスゲ。畳み込みニューラル ネットワークを使用したテキストチャ合成。神経情報処理システムの進歩,28,2015。

[16] ムハンマド・ギファリー、W・バステアーン・クライン、張孟傑、そしてデヴィッド・バルドゥツツィ。マルチタスク オートエンコーダによるオブジェクト認識のドメイン一般化。議事録では、コンピューター ビジョンに関する IEEE 国際会議のページ 2551 ~ 2559 年,2015 年。

[17] イアン・J・グッドフェロー、ジャン・ブージェ＝アバディ、メディ・ミルザ、ピング・シュウ、デヴィッド・ウォード＝ファーリー、シェルジル・オゼール、アーロン・クールヴィル、ヨシュア・ベンジオ。生成的な敵対的ネット。統計,1050:10、2014年。

[18] イシャーン・グラジャニとデビッド・ロペスパス。失われたドメインの一般化を求めて。学習表現に関する国際会議にて,2020年。

[19] 何開明、張祥宇、任少清、孫建。画像認識のための深層残差学習。コンピューター ビジョンとパターンに関する IEEE 会議の議事録
認識,770-778 ページ,2016 年。

[20] クリスティーナ・ハインツェ＝デムルとニコライ・マインスハウゼン。条件付き差異ペナルティとドメイン シフトの堅牢性。Ma-chine Learning,110(2):303-348,2021。

[21] ファン・ウェンジャン、ワン・ハオ、シア・ジアオ、ワン・チェンヤン、そして張建国さん。分布外検出のための密度主導の正則化。神経情報の進歩処理システム,35:887-900,2022。

[22] Xun HuangとSerge Belongie。任意のスタイル転送
アダプティブインスタンス正規化によるリアルタイム。コンピューター ビジョンに関する IEEE 国際会議議事録,1501 ~ 1510 ページ,2017 年。

[23] ゼイ・ファン、ハオハン・ワン、エリック・P・シン、ドン・ファン。自己挑戦により、クロスドメインの一般化が向上します。で
コンピューター ビジョンに関するヨーロッパ会議,124 ~ 140 ページ。スプリングー,2020年。

[24] キム・デヒ、ユ・ヨンジュン、パク・スンヒョン、キム・ジンギュ、そしてイ・ジェクーさん。Selfreg: ドメイン一般化のための自己監視型対照的規則化。議事録では、
コンピュータービジョンに関するIEEE/CVF国際会議、9619 ~ 9628 ページ,2021 年。

[25] ディーデリク・P・キングマとマックス・ウェリング。自動エンコーディングの変数
ナショナルペイ。統計,1050:1,2014。

[26] デヴィッド・クルーガー、イーサン・カバレロ、ヨーン・ヘンリック・ヤコブセン、エイミー・チャン、ジョナサン・ピナス、チャン・ディンファイ、レミル・ブリオールとアーロン・クールヴィル。リスク外挿 (rex) による分布外の一般化。機械学習に関する国際会議,5815 ~ 5826 ページ。PMLR,2021年。

[27] ヤン・ルカン、ヨシュア・ベンジオ、ジェフリー・ヒントン。深い学ぶ。自然,521(7553):436-444,2015。

[28] ジェホ・リーとマキシム・ラギンスキー。ワッサースタイン距離を使用したミニマックス統計学習。神経情報処理システムの進歩,31,2018。

[29] Da Li,Yongxin Yang,Yi-Zhe Song,Timothy
ホスペデール。一般化の学習: ドメイン一般化のためのメタ学習。AAAI 会議の議事録にて
人工知能,第 32 巻,2018 年。

[30] Da Li,Yongxin Yang,Yi-Zhe Song,Timothy M
ホスペデール。より深く、より広く、より高度な領域の一般化

ション。 IEEE 国際会議の議事録では、
コンピューター ビジョン,5542 ~ 5550 ページ,2017 年。

[31] Pan Li, Da Li, Wei Li, Shaogang Gong, Yanwei Fu, Tim-othy M Hospedales. ドメインメインの一般化のためのシンプルな機能拡張。コンピューター ビジョンに関する IEEE/CVF 国際会議議事録, 8886 ~ 8895 ページ、2021年。

[32] Xiaotong Li, Yongxing Dai, Yixiao Ge, Jun Liu, Ying Shan、そしてリンコ・ドゥアン。分布外一般化のための不確実性モデリング。国際会議では、学習表現, 2021 年。

[33] Ya Li, Mingming Gong, Xinmei Tian, Tongliang Liu、大成タオ。条件付き不変表現によるドメインの一般化。 AAAI 会議の議事録にて 人工知能, 第 32 巻, 2018 年。

[34] Qiijin Lu, Yipeng Zhang, Mingjian Lu、および Vwani Roy-chowdhury。アクション条件付きのオンデマンドのモーション生成。第 30 回 ACM 国際マルチメディア会議議事録, 2249 ~ 2257 ページ, 2022 年。

[35] ワン・ルー、ジンドン・ワン、イー・強・チェン、シン・ノ・ジャリン・パン、チュン・ユ・フー・ビン・チン。意味と区別の混同一般化可能なセンサーベースのクロスドメインアクティビティ認識。インタラクティブ、モバイル、ウェアラブルおよびユビキタス テクノロジー, 6(2):1-19, 2022。

[36] サイド・モティアン、マルコ・ビッシリ、ドナルド・A・アジェロー、ジャンフランコ・ドレット。統合された深い監視付きドメインの適応と一般化。コンピューター ビジョンに関する IEEE 国際会議議事録, 5715 ~ 5725 ページ、2017年。

[37] クリカモル・ムアンデット、デビッド・バルドゥツィ、ベルンハルト・シヨルコップ。不変特徴表現によるドメインの一般化。機械に関する国際会議で 学習, 10 ~ 18 ページ。 PMLR, 2013 年。

[38] ヴァイシュナフ・ナガラジャン、アンダース・アンドレアッセン、ペーナム・ネイシャブル。分布外一般化の障害モードを理解する。国際会議では、学習表現, 2020 年。

[39] ナム・ヒョンソプとキム・ヒョウン。適応的にスタイル不変のニューラル ネットワークのバッチインスタンス正規化。神経情報処理システムの進歩, 31、2018。

[40] ナム・ヒョンソプ、イ・ヒョンジェ、パク・ジョンチャン、ウォンジュン・ユン君、ユ・ドンゲン君。スタイルの偏りを減らすことでドメインギャップを減らします。 IEEE/CVF 会議の議事録にて コンピュータビジョンとパターン認識について、8690 ページ– 8699, 2021。

[41] オーレン・ヌリエル、サギー・ベナイム、ライオール・ウルフ。並べ替えると：画像分類におけるグローバル統計への偏りを軽減します。 IEEE/CVF 会議の議事録にて コンピュータビジョンとパターン認識について、9482 ページ – 9491, 2021。

[42] シンチャオ・ペン、チンシュン・バイ、シーデ・シア、ジジュン・ファン、ケイト・サエンコとボ・ワン。マルチソースのモーメントマッチングドメイン適応。コンピューター ビジョンに関する IEEE/CVF 国際会議議事録, 1406 ~ 1415 ページ、2019年。

[43] 風春喬、龍昭、西鵬。学ぶこと 単一ドメインの一般化を学びます。議事録では、コンピュータビジョンとパターンに関するIEEE/CVFカンファレンス Recognition, 12556 ~ 12565 ページ, 2020 年。

[44] アレクサンドル・ラメ、コランタン・ダンセット、マチュー・コード。Fishr: 分布外の不変勾配分散一般化。機械に関する国際会議で 学習, 18347 ~ 18377 ページ。 PMLR, 2022 年。

[45] アレクサンダー・ロビー、ジョージ・J・パパス、ハメド・ハッサニ。モデルベースのドメインの一般化。神経情報処理システムの進歩、34:20210–20229, 2021。

[46] 佐川詩織、バン・ウェイ・コー、橋本辰徳、パーシー・リャン。分布的に堅牢なニューラル ネットワークグループシフト: 最悪の場合の一般化のための正則化の重要性について。 arXiv プレプリント arXiv:1911.08731, 2019。

[47] スワミ サンカラナヤナンとヨゲシュ バラジ。メタ学習ドメインの一般化のため。医療とのメタラーニングにおいて イメージングと医療情報学アプリケーション, 75 ~ 86 ページ。エルゼビア, 2023年。

[48] ユゲ・シー、ジェフリー・シーリー、フィリップ・トール、N・シッターズ、アウニ・ハヌン、ニコラ・ウスニエ、ガブリエル・シンナエブ。勾配ドメイン一般化のためのマッチング。 2021 年の学習表現に関する国際会議にて。

[49] アマン・シンハ、ホンソク・ナムクン、ジョン・ドゥチ。原則に基づいた敵対的トレーニングにより、ある程度の配布の堅牢性を証明します。学習に関する国際会議において 代表者, 2018年。

[50] バオチェン・サンとケイト・サエンコ。深いサンゴ: 相関関係ディープドメイン適応のための調整。コンピューター ビジョンに関する欧州会議, 443 ~ 450 ページ。スプリングer、2016年。

[51] エリック・ツェン、ジュディ・ホフマン、ニン・チャン、ケイト・サエンコ、トレバー・ダレル。深いドメインの混乱: 最大化ドメインの不変性。 arXiv プレプリント arXiv:1412.3474, 2014。

[52] ウラジミール・ヴァブニク。学習理論のリスク最小化の原則。神経情報処理システムの進歩, 4, 1991。

[53] ウラジミール・ヴァブニク。統計的学習理論の性質。シュプリンガーの科学とビジネス メディア, 1999 年。

[54] ヘマン・ヴェンカテスワラ、ホセ・エウゼビオ、シャヨク・チャクラボルティ、そしてセトゥラマン・パンチャナサン。ディープハッシュネットワーク監視されていないドメイン適応。議事録では、コンピューター ビジョンとパターン認識に関する IEEE 会議, 5018 ~ 5027 ページ, 2017 年。

[55] ヴィカス・ヴェルマ、アレックス・ラム、クリストファー・ベッカム、アミール・ナジャフィ、ヨアニス・ミトリアス、デビッド・ロペス・パス、ヨシュア・ベンジオ。多様体の混合: 隠れ状態を補間することにより表現が改善されました。機械に関する国際会議で 学習, 6438 ~ 6447 ページ。 PMLR, 2019年。

[56] リッカルド・ヴォルピ、ホンソク・ナムクン、オザン・セナー、ジョン・C・ドゥキ、ヴィットリオ・ムリーノ、シルビオ・サヴァレーゼ。一般化する敵対的なデータ拡張を介して、目に見えないドメインにアクセスします。神経情報処理システムの進歩, 31, 2018。

[57] ワン・ハオハン、ゼシュエ・ヘ、ザカリ・C・リプトン、エリック・P・シン。表面的な統計を投影することで堅牢な表現を学習します。学習に関する国際会議において 代表者, 2018年。

[58] ジンドン・ワン、ウェンジェ・フェン、イー・強・チェン、ハン・ユー、メイユ・ファン氏とフィリップ・S・ユー氏。マニフォールド埋め込みディストリビューション調整による視覚的ドメイン適応。議事録では、

- マルチメディアに関する第 26 回 ACM 国際会議、402 ~ 410 ページ、2018 年。
- [59] ジンドン・ワン、クリン・ラン、チャン・リユー、イードン・欧陽、タオ・チン、ワン・ルー、イー強・チェン、ウエンジュン・ゼン、フィリップ・ユー。目に見えないドメインへの一般化: ドメインの一般化に関する調査。知識およびデータ エンジニアリングに関する IEEE トランザクション、2022 年。
- [60] ユリン・ワン、シューラン・パン、シージ・ソン、ホン・チャン、ガオ・ファン、チェン・ウー。ディープネットワーク向けの暗黙的なセマンティックデータの拡張。神経情報処理システムの進歩、32、2019。
- [61] ギャレット・ウィルソンとダイアン・J・クック。教師なしディープドメイン適応の調査。インテリジェント システムおよびテクノロジーに関する ACM トランザクション (TIST)、11(5):1-46、2020。
- [62] シェン・ヤン、ファン・ソン、ナンシャン・リー、リンカン・ゾウ、リウ・レン。ミックスアップトレーニングにより教師なしドメイン適応を改善します。統計、1050:3、2020。
- [63] ヤオ・シュフェン、ヤン・バイ、チャン・シンユン、チャン・ユエチェン、スン・チー、ラン・チェン、リー・ルイユ、ペイ・ユー。Pcl: ドメイン汎化のためのプロキシベースの対照学習。コンピュータ ビジョンとパターン認識に関する IEEE/CVF 会議議事録、7097 ~ 7107 ページ、2022 年。
- [64] 張道安、陳明凱、李晨明、黃凌雲、張建国。解きほぐしの集合体: ドメイン一般化におけるドメインのバリエーションを再考する。 arXiv プレプリント arXiv:2302.02350、2023。
- [65] 張道安、李晨明、李浩泉、黃文建、黃凌雲、張建国。教師なし画像セマンティック セグメンテーションにおける位置合わせと均一性を再考する。人工知能に関する AAAI 会議議事録、第 37 巻、11192 ~ 11200 ページ、2023 年。
- [66] 張林峰、陳申、張俊博、東潤平、馬凱生。対照的な深い監督。 Computer Vision – ECCV 2022: 第 17 回欧州会議、イスラエル、テルアビブ、2022 年 10 月 23 ~ 27 日、議事録、パート XXVI、1 ~ 19 ページ。スプリンガー、2022年。
- [67] マービン・チャン、ヘンリック・マークランド、ニキータ・ダーワン、アビシェク・グプタ、セルゲイ・レヴィン、チエルシー・フィン。適応的リスク最小化: グループ分布の変化に取り組むためのメタ学習アプローチ。 arXiv プレプリント arXiv:2007.02931、2020。
- [68] チャン・イーベン、チョン・ホヨン、ジャクリーン・P・ゴ、トンモイ・モンスール、ショーン・A・フセイン、ジョイス・H・マツモト、パトリシア・D・ウォルショー、アリア・ファラー、ミョン・シン・シム、浅野英史、他。深層学習を使用した生理学的高周波振動の特性評価。神経工学ジャーナル、19(6):066027、2022。
- [69] チャン・イーベン、ルー・チジン、トンモイ・モンスール、ショーン・A・フセイン、ジョー・X・チャオ、サラモン・ノリコ、アリア・ファラー、ミョン・シン・シム、浅野英史、ラマン・サンカル 他。ディープラーニングを使用したかん誘発性高周波振動の改良: リバース エンジニアリング アプローチ。ブレインコミュニケーション、4(1):fcab267、2022。
- [70] Fan Zhou、Zhuqing Jiang、Changjian Shui、Boyue Wang、Brahim Chaib-draa。最適なトランスポートとメトリック学習によるドメインの一般化。 arXiv プレプリント arXiv:2007.10573、2020。
- [71] 周海陽、楊永信、ティモシー・ホスベデレス、タオ・シャン。ドメインの一般化のための新しいドメインを生成する方法を学習します。コンピュータ ビジョンに関する欧州会議、561 ~ 578 ページ。スプリンガー、2020年。