



このICCV論文は、Computer Vision Foundationが提供するオープンアクセス版です。

この透かし以外は、受理されたバージョンと同一である；

プロシーディングスの最終出版版はIEEE Xploreで入手できる。


半教師付き学習におけるサンプル適応型補強によるサンプル利用率の向上

Guan^{Gui1}、Zhen^{Zhao2}、Lei^{Qi3}、Luping^{Zhou2}、Lei^{Wang4}、Yinghuan^{Shi1*}。


¹南京大学² シドニー大学³ 南東大学⁴ ウーロンゴン大学 guiguan@smail.nju.edu.cn,
{zhen.zhao, luping.zhou}@sydney.edu.au qilei@seu.edu.cn, leiw@uow.edu.au,
syh@nju.edu.cn

要旨

半教師付き学習では、ラベル付けされていないサンプルは、補強と一貫性の正則化によって利用することができる。しかし、あるサンプルは強力な補強を受けてもなお、高い信頼性で正しく分類され、その結果、損失がゼロに近いことが観察された。これは、これらのサンプルが既によく学習されており、追加的な最適化の利点をもたらさないことを示す。をモデルに加える。このようなサンプルを「ナীবサンプル」と呼ぶ。残念なことに、既存のSSLモデルはナীবサンプルの特性を見落としており、全てのサンプルに同じ学習戦略を適用しているだけである。SSLモデルをさらに最適化するために、我々は素朴なサンプルに注意を払い、より多様な方法でサンプルを増強することの重要性を強調する。サンプル適応型補強 (SAA) とは
この目的のために提案されたのが、以下の2つのモデルである。



(a) 素朴なサンプルの例。



ルールがある：1) サンプル選択モジュール、2) サンプル増強モジュール。具体的には、サンプル選択モジ

ュールは、各エポックにおける過去の学習情報に基づいて素朴なサンプルを選択し、次に、サンプル増強モジュールで素朴なサンプルをより多様な方法で増強する。上記のモジュールの実装が非常に簡単であるため、SAAはシンプルで軽量であるという利点がある。我々はFixMatchとFlexMatchの上にそれぞれSAAを追加し、実験によりSAAがモデルを大幅に改善できることを実証した。例えば、40ラベルのCIFAR-10において、SAAはFixMatchの精度を92.50%から94.76%に、FlexMatchの精度を95.01%から95.31%に向上させた。コードは<https://github.com/GuanGui-nju/SAA>。

*共著者Yinghuan Shi.Guan Gui、Yinghuan Shiは、南京大学国家新型ソフトウェア技術重点実験室および国家医療データ科学研究所に所属。Lei Qiは東南大学コンピューターサイエンス・エンジニア学部。本研究は、NSFCプログラム（62222604、62206052、62192783）、中国博士研究員科学基金プロジェクト（2023T160100）、江蘇省自然科学基金プロジェクト（BK20210224）、およびCCF-Lenovo Bule海洋研究基金の支援を受けている。

(b) トレーニング中のモデルのパフォーマンス。

図1: (a)は素朴なサンプルの例である。(b)はFixMatch学習中のモデル性能を示す。性能の向上は遅いか、あるいは一定期間停滞している。

1. はじめに

手作業によるラベリングのコストを削減するため、ラベル付けされていないデータからどのように学習するかに焦点を当てた半教師付き学習（SSL）は、視覚アプリケーションにおける長年の重要な研究テーマである。近年、データ補強技術と一貫性正則化が、ラベルなしデータを利用する効果的な方法であることが証明されている。例えば、FixMatch [39]は、弱補強バージョンと強補強バージョン間の事前予測の一貫性を促し、わずか40ラベルのCIFAR-10タスクで92.50%の精度を達成した。

しかし、強力な増強を行っても、すべてのラベルなしサンプルが有効に利用されるわけではない。図1aでは、もし強く増強されたバージョンが、次のように正しく分類された場合

信頼度が高く、損失がゼロに近い場合、そのサンプルはすでに十分に学習されており、モデルの性能をこれ以上向上させることはできない。言い換えれば、そのサンプルはモデル学習に有効活用されていないことを意味し、このサンプルを「ナイーブサンプル」と呼ぶ。学習プロセスに多数のナイーブサンプルが含まれる場合、図1bに示すように、モデル性能の向上が遅くなったり、停滞したりする可能性がある。

残念ながら、既存のSSLモデル[34]は、全てのサンプルが効果的に利用されているかどうかという重要な点を見落としている。一般的に、これらのモデルは全てのサンプルに同じ固定された強オグメント戦略を適用し、その結果、モデル訓練に利益をもたらさない強オグメントバージョンが生じる。

この問題を緩和する鍵は、新たな学習戦略を通じて、**素朴なサンプルの価値をどのようにさらに探求するか**にあることを強調する。私たちを思い起こさせる自然なアイデアは、**素朴なサンプルを識別し、増強後にその多様性を増加させるサンプル適応的増強（SAA）を開発することである**。我々の提案するSAAはシンプルでありながら効果的であり、2つのモジュールから構成される：1)サンプル選択モジュールと2)サンプル増強モジュールである。前者は各エポックにおいて**素朴なサンプルを抽出し**、後者は**素朴なサンプルに対してより多様な増強戦略を適用する**。具体的には、サンプル選択モジュールでは、まず各エポックでサンプルの履歴損失を指数移動平均（EMA）で更新し、次にこれらのサンプルを2つの部分に分割する。ヒストリカル損失が小さい方のサンプルは、**ナイーブサンプルとみなされる**。履歴損失はサンプルのモデル学習への影響を捉えるので、このアプローチにより、効果的に利用されておらず、より多様な増強の恩恵を受けるであろうサンプル

を特定することができる。サンプル補強モジュールでは、複数の強力な補強画像を再グループ化することで、**ナイーブサンプルのより多様な補強バージョンが得られ**、残りのサンプルは元の強力な補強で適用される。

提案するSAAは実装が簡単で、PyTorchのFixMatchやFlexMatchに提案するモジュールを追加するのに必要なコードは数行だけです。また、メモリと計算の面でも軽量です。つまり、SAAは2つのベクトルを追加し、各エポックで更新するだけでよく、SSLモデルを改善するための効率的なソリューションです。

FixMatchとFlexMatchをSAAで拡張し、SSLベンチマークで実験を行った。実験の結果、SAAがパフォーマンスを大幅に改善できることが実証された。まとめると、我々の貢献は以下ようになる：

- **我々は、効果的に利用されていないサンプルを特定し、それらにもっと注意を払うべきであることを示す。** データ補強に基づく一貫性正則化の下では、いくつかの強く補強されたバージョンはモデル学習に有益ではなく、その結果、これらのサンプルの値は十分に利用されず

は、モデル性能の向上を遅らせる。我々はこれらを「ナイーブ・サンプル」と呼び、新たな学習戦略で学習する必要があることを強調する。

- **我々は、ナイーブサンプルをより有効に利用するためにSAAを提案する。**拡張されたバージョンがモデル学習に役立つ確率を高めるために、ナイーブサンプルを識別し、より多様な方法で拡張するための、シンプルで効果的な方法であるサンプル適応型拡張（SAA）を提案する。

- **SSLベンチマークでSAAの有効性を検証した。**FixMatchとFlexMatchを基本フレームワークとして使用し、我々のアプローチが最先端の性能を達成できることを証明した。例えば、40ラベルのCIFAR-10において、SAAはFixMatchの精度を92.50%から94.76%に向上させ、FlexMatchの精度を95.01%から95.31%に向上させた。

2. 関連作品

2.1. 半教師付き学習

一貫性正則化（CR）[2]は、半教師付き学習（SSL）においてラベル付けされていないデータを利用する主な方法である。従来の実装は、サンプルに摂動を与え、モデルが一貫した事前予測を維持するように促すものである。摂動の方法は様々な方法で研究されており、例えば確率的増強と脱落[25, 35]、特徴摂動[24]、敵対的摂動[24]などがある。

ーション[30]、モデル摂動[42]。[4,44,3]は、画像の混合にmixupを適用しており、これも画像の摂動である。強オーグメンテーション技術[7, 10]により、FixMatchは弱オーグメンテーションと強オーグメンテーションの間に一貫した正則化を適用する。このアプローチはフレームワークを大幅に単純化し、半教師付き学習のマイルストーンにおけるブレイクス

ルをもたらしした。我々が以前に分析したように、フレームワークは全ての画像に同じ固定増強戦略を適用するため、ナイーブサンプルが十分に活用されない結果となる。

FixMatchフレームワークの優位性により、現在、多くのSSL作品[52, 12, 48, 55, 16, 13, 54]がFixMatchフレームワークに基づいてさらなる最適化を図っているが、ナイーブサンプルの活用の有効性を考慮した作品はない。[12, 54]は、ラベル無しデータの分布を学習することで、擬似ラベルの質を向上させることに焦点を当てている。[55, 16]は、サンプルやスーパークラス間の類似関係の学習に焦点を当てている。[13, 48, 52]はいずれも信頼度の低いサンプルの活用を強調している。これらの研究はまた、モデルがある一定の反復回数内でより多くのサンプルを学習することにある程度許可するが、それでもなお、増強の妥当性のissueを無視し、結果として、これらの増強されたサンプルはまだモードの学習に役に立たない可能性がある。

我々の知る限り、SSLの研究ではナイーブサンプルの利用を考慮したものはない。[52]は各カテゴリーを異なるように扱い、各カテゴリーごとに閾値を調整するが、我々は各サンプルをカテゴリーに関係なく異なるように扱うことを考えている。

2.2. 採掘の難しい例

我々の研究はハードサンプルマイニングと多少関連しているが、我々がモデル学習に有益でない素朴なサンプルに焦点を当てているのに対し、彼らはモデル学習にダメージを与えるハードサンプルに焦点を当てているという違いがある。ハードサンプルを選択するためのより一般的なアプローチは、サンプルとグラントゥールースの間の損失情報に依存することである[37, 46, 29, 38]。これは我々のアプローチと関連しているが、ラベル付けされていないサンプルは、グラントゥールースがないため、その一貫性損失によって選択される。これに加えて、距離メトリクス[49, 22]や偽陽性サンプル[20, 9, 11, 14]は、ハードサンプル選択の一般的な手法である。しかし、これらのハードサンプルの削減方法のほとんどは、SSL下では実用的ではないラベルに依存する。我々の提案する手法も、この分野の手法も、サンプルの抽出を行うが、その違いは、学習が困難なハードサンプルの選択に重点を置くのに対し、我々は、モデルの学習に寄与しないナイーブサンプルに重点を置く点である。

2.3. 日付 拡張

データ増強はデータ空間を拡大する効果的な方法であり[36]、以下のカテゴリーに大別される： 1) 単一摂動 [31, 21, 10]. 2) 画像混合に基づく [43, 53, 50, 19]; 3) 学習ベース[40, 28, 15]、4) サーチベース[6, 27, 7]。1つの画像に摂動を与える一般的な操作には、幾何学的変

換、色変換、ノイズ注入[31]、ランダム消去[56]、カーネルフィルタ[21]、カットアウト[10]などがある。[43, 53]は2つの画像の内容を直接混合し、[50]は画像パッチを混合し、[8, 19]は内容とスタイルを混合する。については学習ベースの戦略、敵対的トレーニング[40, 47]、そしてGANベース[28, 15]は、拡張画像を得るためにネットワークを学習する。[6, 27]は、探索戦略を用いて、摂動空間における最良の組み合わせを見つける。

しかし、単一摂動や画像混合ベースの手法は、画像の多様性を高めることに限定される。学習や探索に基づく手法では、モデル学習を容易にする拡張画像が得られるものの、その消費時間は膨大であるため、時間のかかるCRベースのSSLモデルの学習には適さない。[7]はランダム変換を組み合わせ、探索プロセスを削除する、であり、SSLモデルに有利である。[17]は画像とこれは画像の多様性を高め、いくつかのタスクで有効であることが検証されている。我々の補強は[17]に関連しているが、パッチではなく画像年齢を補強した。これについては実験的なセクションで述べる。

3. 予備知識と背景

3.1. 問題設定

半教師付き学習では、ラベル付けされた集合を $X = \{(x_1, y_1), (x_2, y_2), \dots, (x_M, y_M)\}$ 、ここで y_i は次のラベルである。
 また、ラベルなし集合 $U = \{u_1, u_2, \dots, u_{N_l}\}$ は i 番目のラベルなしサンプルを表し、典型的には $|X| \ll |U|$ である。実装ではサンプルは、ラベル付きデータ X のバッチとラベルなしデータ U のバッチで、反復ごとにバッチごとに提供される。
 がSSL研究の焦点である。一般的に、一貫性ラベル付けされていないデータは摂動によって異なるバージョンを生成し、モデルはこれらのバージョンの表現または予測に一貫性を持たせる。

3.2. CRベースのSSLモデルのための予備知識

強力な増強は、一貫性の正則化を適用する良い手段であり、FixMatch [39]はこのアイデアの代表である。最近の多くの半教師付き研究[52, 48, 26, 55, 16]も、さらなる最適化の基礎としてFixMatchを使用している。

FixMatchの基本的な考え方は、弱補正バージョンに擬似ラベルを生成し、それを対応するラベルのトレーニングターゲットとして使用することである。
 強オグメント版。このうち、弱いオグメント $\alpha(\cdot)$ は標準的なフリップ操作とシフト操作を含み、強いオグメント戦略 $A(\cdot)$ はRandAug-からなる。ment[7]とCutOut[10]がある。

p^w 、 p^s はそれぞれ $\alpha(u_i)$ 、 $A(u_i)$ に対するモデルの予測を表すとする。そして、このラベル付けされていないサンプルに対する一貫性正則化に基づく教師なし損失は次のようになる、

$$L = \sum_{i=1}^{|U|} 1(\max(p^w) \geq \tau) H(p^w, p^s). \quad (1)$$

ここで、 $H(p_1, p_2)$ は p_1 と p_2 の間の標準クロスエントロピーを表し、 τ_c は信頼度の高い擬似ラベルのみを保持するためにあらかじめ定義された閾値

である。FixMatch[39]で議論されているように、 τ_c はSSLにおける確証バイアス[1]を回避するために、一般的に大きな値として設定される。 p_i が $\alpha(x_i)$ のモデルの予測を表すすると、labeledサンプルに対する教師付き損失は次のようになる、

$$L_{\text{sup}} = \frac{1}{|X|} \sum_{i=1}^{|X|} H(q_i, y_i). \quad (2)$$

最後に、総損失は次のように表すことができる、

$$L = L_{\text{sup}} + \lambda L_{\text{unsup}}. \quad (3)$$

ここで、 λ は L_{unsup} の重みである。

$$L_{\text{unsup}} = \sum_{i=1}^{|U|} \min_{c \in \mathcal{C}} H(p_i^w, p_i^c)$$

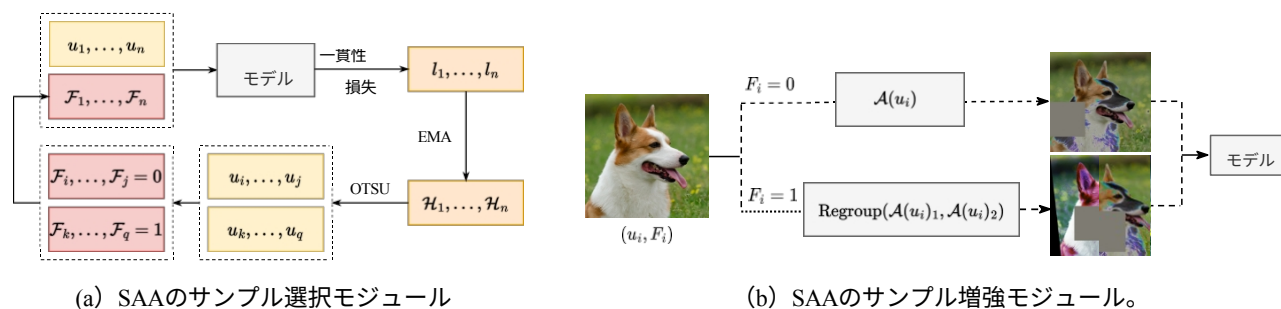


図2: 我々の手法SAAの概要。SAAの核となる洞察は、サンプルのオーグメンテーションを動的に調整することである、

これにより、ナイーブなサンプルをより効果的に使用することができる。詳細には、SAAはサンプル選択モジュールとサンプル増強モジュールの2つのモジュールから構成される。(a).各サンプル u_i はマーカー F_i と履歴損失 H_i に対応する。各エポックにおいて、サンプルの一貫性損失は記録され、履歴損失 H_i はEMAで更新される。そして、過去の

の損失を考慮し、OTSUごとにサンプルを2つに分けた。ヒストリカル・ロスがより小さいサンプルは、ナイーブである。

(b). サンプル u は、マーカー F によって異なる方法で増強される。 $F_i = 0$ の場合は1回、 $F_i = 1$ の場合は2回強く増強され、増強された2つの画像は1つの画像に再グループ化される。この再編成は、上下2つに分けてもよいし、2つに分けてもよい。

左右は0.5の確率でランダムに選ばれる。

3.3. ナイーブサンプルの特徴と影響

FixMatchを例にとって、図3に示すように、ナイーブなサンプルとそうでないサンプルの損失を別々に追跡した。図3は、閾値の干渉を排除するために、閾値なしの元の損失を示している。




図3: ナイーブでないサンプル (下) とナイーブなサンプル (上) の損失。

損失値に対する信頼閾値のほとんどのエポックにおいて、ナイーブな

サンプルのクロスエントロピー損失は0に近く、 $A(u_i)$ の学習はモデルの学習進捗に寄与しないことを示している。

同じ増強により、ナイーブでないサンプルは、長期的にモデルの最適化を促すことができるが、ナイ

4.SAA: サンプル適応型補強の使用 半教師付き学習を支援する

SAAは、素朴なサンプルに注目し、モデル学習を支援するための価値を探索することで、素朴なサンプルが効果的に活用されていないという問題に対処することを目的としています。この目標を達成するために、SAAは2つのモジュールを設計する：サンプル選択モジュールとサンプル増強モジュールである。最初のモジュールの機能は、素朴なサンプルを識別することです。

一方、2番目のモジュールの機能は、より多様な増強戦略を素朴なサンプルに適用し、効果的な学習を促進することである。

ナイーブなサンプルはそうすることができない。このことは、ナイーブサンプルに十分な注意を払い、その潜在的価値をより良く利用できる新しい増強戦略を開発する必要性を裏付ける。さらに、学習プロセスにおいて

ナイーブサンプルが多すぎると、図1bに示すように、モデル性能の向上を妨げる可能性がある。これらの結果は、SSLタスクにおいてナイーブサンプルを適切に識別し、取り扱うことの重要性を強調している。

我々は、信頼度の高い擬似ラベルの数など、性能向上の遅れの原因となるいくつかの要因があることを強調したい。また、閾値を調整する[52]、他の学習可能な信号を見つける[55]など、問題を解決する方法は複数ある。本研究では、データの増強に集中する。我々のアプローチは上記の方法と併用でき、SSLにとって有益であることに注意すべきである。

4.1. サンプルの選択

つのベクトル $H = \{H_1, H_2, \dots, H_N\}$, $F =$ を導入する。

^{12N}ここで、 N はラベルなしサンプルの数である。 H は、各ラベルなしサンプルについて、過去の一貫性損失情報を記録し、 F は、各ラベルなしサンプルについて、過去の一貫性損失情報を記録する。非標識サンプルは素朴なサンプルである。ラベルのないサンプルは

u_i 、このモデルは、弱補強版と強補強版の間の整合性損失 \mathcal{L} を計算する。

シジョンを t 番目のエポックに 1 回更新する。次に、指数関数で H^t を更新する。これは次のように表すことができる：

$$H_i^t = (1 - \alpha)H_i^{t-1} + \alpha l_i^t. \quad (4)$$

モデル・パラメータもEMA [39, 52]で更新されるため、導入したパラメータ α は追加的なモデル・パラメータではないことに注意されたい。過去の損失情報は、強く拡張されたバージョンのモデルへの影響の大きさを反映することができるため、ナイーブサンプルの決定の基礎となる。OTSU[33]は、計算が容易であるため、閾値セグメンテーションの一般的な手法である。

アルゴリズム1: FixMatchにSAAを装備する

入力: ラベル付きデータ・バッチ $B_x = \{(x_i, y_i)\}^M$, ラベルなしデータ・バッチ $B_u = \{u_i\}^N$, 教師なし損失重み λ , 事前学習エポック T' , 全学習エポック T , 拡張戦略 $\alpha(-)$, $A(-)$, $A'(-)$, 過去の損失 $H = \{H_1, H_2, \dots, H_T\}$, マーク $F = \{F_1, F_2, \dots, F_N\}$.

```
1 for  $t \leftarrow 1$  to  $T$  do
2   FixMatch の実行; // 最初の  $T'$  エポックで FixMatch としてトレーニングする。
3 エンド
4 for  $T' \leftarrow 1$  to  $T$  do
5    $L_{sup} = 1/|B_x| \sum_{i=1}^{|B_x|} H(q_i, y_i)$ ; // FixMatchにおけるスーパーバイズド・ロスを計算する。
6   for  $i \leftarrow 1$  to  $N$  do
7     摂動 $\alpha(-)$ を $u_i$ に適用; // FixMatchにおける弱いオーグメンテーション
8      $F_i$ に従って、 $u_i$ に補強 $A(-)/A'(-)$ を適用する。
9     計算損失  $l_i = H(\arg \max p_m(\alpha(u_i)), p_m(A(u_i)))$ ; // FixMatchにおける一貫性損失
10  終了
11   $L_{unsup} = 1/|B_u| \sum_{i=1}^{|B_u|} 1(\max p_m(\alpha(u_i)) \geq \tau) l_i$ ; // FixMatchにおける教師なし損失
12  更新履歴損失  $H_t = (1 - a)H_{t-1} + al_t$ ; // SAAにおけるサンプル選択
13  更新マーク  $F_i = 1(H_t^i \leq \text{OTSU}(H_t^i))$ ; // SAAにおけるサンプル選択
14 エンド
```

このような閾値に基づき、各エポックにおける過去の損失閾値を計算する。これにヒントを得て、各エポックにおける過去の損失閾値を計算する：

$$\tau_s = \text{OTSU}(H_1, H_2, \dots, H_N). \quad (5)$$

OTSUは過去の損失に基づいて適応的にサンプルを2つの部分に分割する。過去の損失が小さいサンプルはナイーブサンプルとみなされます。

をモデルに追加する。次にFを更新する：

$$F_i = 1(H_i \leq \tau_s). \quad (6)$$

素朴なサンプルの判定はエポック毎に行われること

がわかる。言い換えれば、あるサンプルが

はモデルの性能に関係する。訓練過程では、Fに複数のシフトがあり得ることに注意すべきである。一方、もしサンプルが

を素朴なサンプルとすると、無効な学習を避けるために、より多様なオーグメンテーションを適用する。一方、このより多様な補強はサンプルにとって摂動が大きすぎ、モデルに悪影響を与える可能性があるため、これらのサンプルの補強戦略は適時に元の戦略に戻るよう調整する必要がある。

ナイーブでないサンプルとナイーブなサンプルに、それぞれ異なる補強を適用する。前者は一方、後者は新しい補強 A' を適用することになり、補強バージョンの難易度が上がる。これは次のように表すことができる：

$$\text{Augmented}(u) = \begin{matrix} A \\ (u_i), F_i = 1 \end{matrix} \quad (7)$$

4.2. サンプルの補強

すなわち、複数の $A(u_i)$ を新しい画像にグループ化し直す。形式的には、新しい増大画像 $A'(u_i)$ は、次のようになります。
と表現される：

$$A'(u_i) = \text{Concat}(\text{Cut}(A(u)_{i1}), \text{Cut}(A(u)_{i2})).$$

(8).

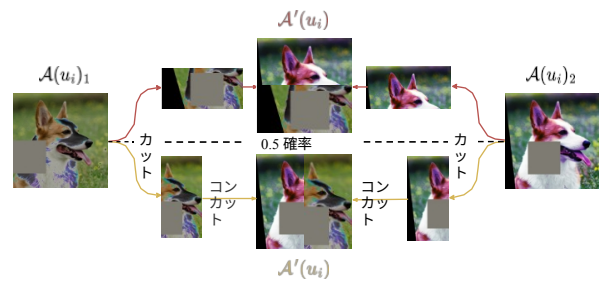
図4に示すように、2つの強く増強されたイメージ $A(u)_{i1}$ 、 $A(u)_{i2}$ 。新しい増強イメージ $A'(u_i)$ を作るために、以下の2つのうち1つをランダムに選ぶ。

1) 上下連結： $A(u)_{i1}$ の上半分と $A(u)_{i2}$ の下半分を取り、それらを連結して新しい画像を作る。2) 左右連結： $A(u)_{i1}$ の左半分と、 $A(u)$ の右半分を取り、それらを連結して新しい画像を作る。

$A(u)_{i2}$ 、それらを連結して新しい画像を作成する。

図4： 素朴なサンプルに対する増強。

画像の再グループ化は、複数の増強された画像を新しい画像に合成することで、画像の多様性を高める技術である。これはシンプルで効果的なソリューションである。
のような過去の作品で、その有効性が示されている。



方法	ラベル40枚	CIFAR-10 250ラベル	4000ラベ ル	400ラベル	CIFAR-100 2500ラベル	10000ラベ ル	ラベル40 枚	SVHN 250ラベル	1000ラベ ル	STL-10 1000ラベル
平均教師	29.91±1.60	62.54±3.30	91.90±0.21	18.89±1.44	54.83±1.06	68.25±0.23	63.91±3.98	96.55±0.03	96.73±0.05	-
ミックスマッチ	63.81±6.48	86.37±0.59	93.34±0.26	32.41±0.66	60.42±0.48	72.22±0.29	69.40±8.39	95.44±0.32	96.31±0.37	38.02±8.29
リミックスマッチ	90.12±1.03	93.70±0.05	95.16±0.01	57.25±1.05	73.97±0.35	79.98±0.27	75.96±9.13	93.64±0.22	94.84±0.31	75.51±1.25
ダッシュ	91.84±4.31	95.22±0.12	95.76±0.06	55.17±1.36	72.15±0.19	77.23±0.21	96.97±1.59	97.83±0.10	97.97±0.06	83.17±0.80
コーマッチ	93.09±1.39	95.09±0.33	95.57±0.04	-	-	-	-	-	-	79.80±0.38
エスエルエー	94.83±0.32	95.11±0.27	95.79±0.15	58.56±1.41	72.37±0.44	77.68±0.24	94.37±2.91	95.08±1.08	95.84±0.24	-
NPマッチ	95.09±0.04	95.04±0.06	95.89±0.02	61.09±0.99	73.97±0.26	78.78±0.13	-	-	-	-
シムマッチ	94.40±1.37	95.16±0.39	96.04±0.01	62.19±2.21	74.93±0.32	79.42±0.11	-	-	-	89.70±0.82
フィックスマッチ [†]	92.50±0.67	95.10±0.04	95.81±0.05	53.17±0.51	72.64±0.17	77.60±0.09	96.24±0.98	97.54±0.04	97.98±0.02	85.27±1.15
フィックスマッチ (SAA付き)	94.76±0.99	95.21±0.07	96.09±0.07	54.29±0.73	73.18±0.21	78.71±0.20	97.01±0.72	97.68±0.07	98.06±0.06	87.92±1.46
フレックスマッチ [†]	95.01±0.09	95.08±0.10	95.82±0.02	60.51±1.54	72.98±0.22	78.15±0.17	92.42±2.60	92.98±1.59	93.54±0.28	89.15±0.71
フレックスマッチ (SAA付き)	95.31±0.16	95.40±0.19	96.14±0.08	61.87±1.94	75.01±0.41	79.88±0.34	93.15±2.54	93.25±2.41	94.41±0.27	90.85±0.82
完全監督制		95.38±0.05			81.70±0.09			97.87±0.02		-

表1: CIFAR-10、CIFAR-100、SVHN、STL-10での性能比較。最近のSSL作品[42, 3, 4, 48, 26, 41, 55, 45]と性能を比較。それぞれFixMatch[39]とFlexMatch[52]の上にSAAを適用した。公正な比較のために、FixMatchとFlexMatchを全く同じ乱数シードの下で再実行した（[†]で示す）。完全教師ありの比較はFlexMatch [52]に従ったもので、弱いデータ補強を適用し、全てのラベル付きデータで実施した。実験によると、SAAはSSLモデルに対して大きな改善をもたらす。FlexMatchを基本フレームワークとして選択した場合、性能はほとんどの設定でSOTAに達する。

ミックス」[17]。学習ベースのデータ補強法（モデル学習に適した補強画像も得られる）と比較すると、画像再グループ化はメモリや計算オーバーヘッドが少ない。しかし、CutMixの場合、オーグメンテーションはカットされた画像に対して行われるため、元の画像に関する情報が失われる可能性がある。対照的に、我々の手法では、オーグメンテーションは画像全体に適用されるため、元画像に関する情報がより多く保存される。これについては、本論文の実験セクションでさらに説明する。

5. 実験

FixMatchとFlexMatchをベースフレームワークとして、SSLベンチマークデータセット上でSAAの有効性を検証した：CIFAR-10、CIFAR-100 [23]、SVHN [32]、STL-10 [5]。

セクション 5.1 では、具体的な実装の詳細を示す。セクション 5.2 では、まず SAA がモデルのテ

スト精度を向上させ、SSL タスクで SOTA を達成できることを検証する。さらに、同じ反復回数での性能を比較し、SAAがモデルの改善速度を加速できることを検証する。

5.1. 実施内容

CIFAR-10 と SVHN には "WideResNet-28-2"[51]、CIFAR-100 には "WideResNet-28-8"[51]、STL-10 には "ResNet18"[18]を採用した。公正な比較のために、FixMatchとFlexMatchと同じパラメータを使用します。を $\{|B_X| = 64, |B_U| = 7|B_X|, \lambda = 1\}$ とする。テストモデルはEMAによって0.999の減衰率で更新される。Hは同じ方法で同じパラメータ($\alpha = 0.999$)で更新される。


FixMatchとFlexMatchはトレーニングの反復回数を2回に設定しており、²⁰。順序のサンプル履歴損失HとマーカーFを更新する。

タイムリーな方法として、1024回の反復を1エポックとみなし、つまり合計1024回のエポックを学習する。エポック
mentation A' は、最初のトレーニングには適さない。
モデルは100エポック目以降にのみ適用し、歴史的損失Hは最初から記録する。同じ実験を異なるシードで5回繰り返し、以下の結果を報告する。
平均検査精度と分散。


5.2. 主な成績

SAAはベースラインモデルの性能を向上させる
。表1に示すように、SAAはすべての設定においてFixMatchとFlexMatchのテスト精度を向上させることに成功した。例えば、40ラベルのCIFAR-10では、FixMatchとFlex-Matchの平均精度は92.50%と95.01%であったが、SAAを使用することで、平均精度は94.76%と95.31%に向上した。難易度が高く現実的なタスクSTL-10では、SAAによりFixMatchは2.65%、FlexMatchは1.70%精度が向上した。FixMatchとFlexMatchは、完全教師ありの条件下でも、いくつかの設定で優れた結果を出している。例えば、Fix-Matchは4000ラベルのCIFAR-10で95.81%、1000ラベルのSVHNで97.98%の平均テスト精度を達成した。SAAがモデルに与えるブースティング効果はシードによって異なるため、SAAを適用するとモデルの分散がわずかに大きくなることがわかります。図5aに示すように、SAAは5つのシード全てにおいてFixMatchをブーストするが、シードが1の場合は2.51%、2の場合は1.20%のブーストが可能である。

SOTAのパフォーマンスを実現します。 FixMatchをベースとして、SAAはその性能を他のSSLモデルに近づける、あるいはそれ以上にするのに役立ちます。例えば、40ラベルのCIFAR-10において、FixMatch（SAA併用）は94.76%の精度を達成し、これはNP-Matchの0.3%以内です。一方、250ラベルのCIFAR-10では、FixMatch (w/SAA)



(a)異なるシードでの精度



(b)トレーニング中のパフォーマンス (同じシードで)

図5: すべての実験は、40個のラベルを持つCIFAR-10のタスクで行われた。(a)は、5つのシードを持つモデルにおけるSAAの性能向上を示す。種が異なるとSAAの性能向上の度合いも異なるが、総じて着実に性能が向上している。(b)は学習中の性能の伸びを示す。同じ反復数であれば、SAAはモデルの性能を大幅に向上させることができる。

の精度を達成した。

SSLモデル。FlexMatchは、閾値を追加することでFixMatchを改良したものだが、SAAの助けを借りてさらに改良することができる。例えば、40ラベルのCIFAR-10において、SAAはFlexMatchの平均精度を95.31%まで向上させた。より困難なタスクでは、2500ラベルのCIFAR-100とSTL-10において、SAAはFlexMatchの平均精度を75.01%と90.85%に向上させ、現在のSSLモデルを凌駕した。アンバランスなデータセットの場合、FlexMatchの各クラスに対する閾値推定値は大きな偏差を生じる可能性があり、これがSVHNタスクにおいてFlexMatchの性能が低い理由である。SVHNは単純なタスクであるため、FixMatchの固定された高いしきい値の方が有利である。FixMatchにSAAを適用することで、FixMatchの性能をさらに向上させ、既存のSSLモデルを凌駕することも可能である。

SAAはモデル性能の向上を加速する。図5bは、同じシードを使ったモデル学習の性能曲線を示している。例えば、200k番目と400k番目の反復において、SAAはFixMatchの性能をそれぞれ86.72%と87.26%か

ら91.15%と91.11%に向上させる。FlexMatchはまた、モデルがより多くのサンプルを学習できるように信頼度の閾値を調整することで、同じ反復におけるFixMatchの性能を向上させることができる。一方SAAは、**ナイーブサンプル**をより効果的に学習させることができるため、モデルの学習をさらに強化することに成功する。例えば、FixMatchの精度は87.26%に達し、FlexMatchはFixMatchを92.74%まで向上させ、SAAはFlexMatchを94.22%まで向上させた。さらに多くの場合、FixMatchは約200k回目から600k回目の反復の間に性能が停滞していることがわかる。これは、この期間にモデルが、モデル性能の向上には役に立たない、強くオーグメンテーションされたバージョンを大量に学習するためである。

用するサンプルの選択方法

ベースライン-1: 全サンプルに <i>A</i> を適用	92.50±0.67
85.27±1.15 ベースライン-2: 全サンプルに <i>A</i> を適用'	92.98±2.94
83.19±3.98 ベースライン-3: 50%のサンプル (ランダム) に <i>A</i> 'を適用	
94.05±2.00 85.98±2.98	

<i>H</i> にしきい値を設定する:	
固定閾値(0.001)	93.82 ±0.95 85.98±1.00
固定閾値 (0.002)	94.10±1.22 85.22±1.87
固定比率閾値 (25%)	93.10 ±0.89 85.38±1.20
固定比率閾値 (50%)	93.87 ±1.52 86.08±1.97
固定比率閾値 (75%)	93.85 ±2.29 84.29±2.03
OTSU閾値	94.50±1.05 87.92±1.46

表2: Fix- Matchをベースとした実験。Hの閾値の設定には3つの方法がある: 1) 固定値、2) ソートされたHのパーセンタイル、3) 自動OTSU。部門がある。


6. ディスカッション

より多様な補強はすべてのサンプルに適用できるわけではない。我々のアプローチは[17]と異なり、より多様な補強をサンプルのサブセット（すなわち、素朴なサンプル）にのみ適用する。表2にBaseline-1とBaseline-2で示すように、これを実験的に検証した。すべてのサンプルに多様な補強を適用すると、不安定になり、いくつかのタスクで性能が低下することがはっきりとわかる。これは、オーグメンテーションのもとでは、画像によっては意味情報が壊れすぎていることを示している


A'、誤差の蓄積につながる。このことをさらに調べるために、各エポックで無作為に選んだ50%のサンプルに*A*'を適用したところ、モデルの平均テスト精度は次のようになった。

わずかに改善されたが、まだ不安定である。このことはさらに、より多様な増強が必要だが、素朴なサンプルに使うことでしかうまくいかないという感覚を与えてくれる。

素朴なサンプルを適応的に分割する。素朴なサンプルを識別するために、サンプルの過去の整合性損失を使用する。CIFAR-10とSTL-10で閾値を変えてこの手法をテストした。表2に示すように、どちらも



(a) 素朴サンプルの割合。



(b) 2つの素朴サンプルの一貫性損失。

図6: (a)は、モデル学習による素朴サンプルの割合をOTSUで割ったものである。40個のラベルを持つCIFAR-10、40個のラベルを持つSVHN、STL-10について、ナイーブサンプルの割合を記録した。左はFixMatch(w/SAA)、右はFlexMatch(w/SAA)である。(b)は2つの素朴サンプルの一貫性損失を示す。左がFixMatch、右がFixMatch(w/SAA)である。


固定閾値アプローチと固定スケールアプローチはモデルにブースト効果をもたらすが、その効果は不安定であり、データセットによって異なる。例えば、CIFAR-10タスクでは、固定閾値 $\tau_s = 0.002$ がより良いパフォーマンスを示すが、CIFAR-10タスクでは、固定閾値 $\tau = 0.002$ がより良いパフォーマンスを示す。

$\tau_s = 0.001$ はSTL-10タスクでより優れた性能を発揮するため、固定閾値は異なるデータセットに対してよりトリッキーなハイパーパラメータとなる。最初の2つのアプローチと比較すると、OTSUはクロスデータセットタスクに適応しやすいだけでなく、モデルの学習に合わせてチューニングすることができる。図6aは、異なる反復におけるOTSU法による素朴サンプルの割合を示している。素朴標本はタスクの難易度だけでなく、モデルの性能にも関係していることが分かる。より単純なデータセットでは、ナイーブサンプルの割合はより大きく、モデルの性能が上がるにつれて、より多くのサンプルがナイーブサンプルとして扱われる。

SAAはウォームアップを解析した。図7の結果は、100k反復のCIFAR-10のモデルウォームアップが最も良い結果を示している。

これらのサンプルのオーグメンテーション戦略のダイナミックな調整により、大幅に増加する。

パッチではなく画像で補強する。 先行研究 [17]



一方、我々は画像全体にオーグメンテーションを適用し、その後に画像にオーグメンテーションを適用する。この2つの方法を比較する実験を行い、その結果を図8に示す。我々のオーグメント法は、CIFAR-10とSTL-10の両方において、より良好な結果を示した。





図8: 異なるより多様な増強。40ラベルのCIFAR-10とSTL-10で実験。

0.96
0.95
0.94
0.93
0.92
0.91
0.90
0.89



で、より多くの意味情報が保存され、SSLモデルの訓練に安全だからである。

限界。我々が使用するオーグメンテーションは未学習であるため、すべてのオーグメンテーションがモデル学習に貢献できるという保証はない。したがって、SAAは、拡張バージョンがモデルにとって有用である可能性を高める役割を果たす。これに加えて

なぜなら、より多様なオーグメント画像は、より認識しにくいからである

。

はモデルの初期トレーニングにダメージを与える可能性がある。そのため、SAAはウォームアップしたモデルでより良いパフォーマンスを発揮する。しかし、モデルのウォームアップが早すぎると、SAAの

図7: モデルのウォームアップ。実験は40ラベルのCIFAR-10で行われた。

モデルはすでにサンプルを十分に活用しており、さらに

SAAの役割とは、モデルのパフォーマンスを向上させるために必要な、あるいは不必要な機能である。

作用時間が短くなる。

SAAは、拡張されたバージョンがモデルをさらに最適化することを可能にする。図6bは、FixMatchにお

けるSAAの有無による**素朴サンプル**の学習損失を比較したものである。このプロットから、SAAを使用しない場合、100回目のエポック以降、**素朴サンプル**の損失はほとんど0に近づき、強くオーグメントされたバージョンはモデルの学習に役立たないことがわかる。しかし、SAAを用いると、強く拡張されたバージョンがモデル学習に役立つ回数は以下になる。

減少した。

7. 結論

本論文では、まず**ナイーブサンプル**の特徴とモデル学習への影響について議論し、より多くの価値を発見するためにこれらのサンプルに注意を払うべきであることを強調する。この目標を達成するために、我々はSAAを提案する。SAAは、**ナイーブサンプル**をリアルタイムで識別し、モデル学習に貢献できるように、その増強戦略を動的に調整する。我々の実験結果は、SAAが様々なデータセットにおいて、FixMatchやFlexMatchのようなSSL手法の性能を有意に改善することを示している。

参考文献

- [1] Eric Arazo, Diego Ortego, Paul Albert, Noel E O'Connor, and Kevin McGuinness.このような場合、「曖昧さ」が「曖昧さ」の原因となっている可能性があるため、「曖昧さ」が「曖昧さ」の原因となっている可能性がある。In *International Joint Conference on Neural Networks*, pages 1-8.IEEE, 2020.[3](#)
- [2] フィリップ・バックマン、ウアイス・アルシャリフ、ドイナ・プレカッポ。Learning with pseudo-ensembles.*Advances in Neural Information Processing Systems*, 27, 2014.[2](#)
- [3] デヴィッド・ベルテロ、ニコラス・カルリーニ、エキン・D・キューブク、アレックス・クーラキン、キヒョク・ソーン、ハン・チャン、コリン・ラフェル。Remix-match: このような場合、「曖昧さ」が「曖昧さ」である可能性が高い。In *Eighth International Conference on Learning Representations*, 2020.[2](#), [6](#)
- [4] デヴィッド・ベルテロ、ニコラス・カルリーニ、イアン・グッドフェロー、アヴィタル・オリヴァー、ニコラ・パペルノ、コリン・ラフェルミックスマッチ: 半教師付き学習への全体的アプローチ。 *Advances in Neural Information Processing Systems*, 32, 2019.[2](#), [6](#)
- [5] Adam Coates, Andrew Ng, and Honglak Lee.教師なし特徴学習における単層ネットワークの分析。第14回人工知能と統計に関する国際会議講演論文集, 215-223ページ.JMLR Workshop and Conference Proceedings, 2011.[6](#)
- [6] Ekin D Cubuk、Barret Zoph、Dandelion Mane、Vijay Vasudevan、Quoc V Le。Autoaugment: データから補強戦略を学習する。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 113-123, 2019.[3](#)
- [7] Ekin D Cubuk、Barret Zoph、Jonathon Shlens、Quoc V Le。Randaugment: 探索空間を縮小した実用的な自動データ補強。 *IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, 2020.[2](#), [3](#)
- [8] Ali Dabouei、Sobhan Soleymani、Fariborz Taherkhani、Nasser M Nasrabadi。スーパーミックス: ミキシングデータの補強を監視する。 *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 13794-13803, 2021.[3](#)
- [9] Navneet DalalとBill Triggs。人間検出のための指向性グラエントのヒストグラム。このような場合、「人間検出のための指向性勾配のヒストグラム」は、「人間検出のための指向性勾配のヒストグラム」と呼ばれる。Ieee, 2005.[3](#)
- [10] テランス・デブリーズ、グラハム・W・テイラー。Improved regularization of convolutional neural networks with cutout.In *Fifth International Conference on Learning Representations*, 2018.[2](#), [3](#)
- [11] Piotr Dollár, Zhuowen Tu, Pietro Perona, and Serge Belongie.積分チャネルの特徴。2009.[3](#)
- [12] ユエ・デュアン、レイ・チー、レイ・ワン、ルーピン・チュウ、インファン・シー。Rda: Reciprocal distribution alignment for robust semi-supervised learning.*European Conference on Computer Vision*, pages 533-549.Springer, Cham, 2022.[2](#)
- [13] 李齊、王磊、周魯平、石英環、楊高。Mutexmatch: Mutex-based consistency regularization による半教師付き学習。*Transactions on Neural Networks and Learning Systems*, 2022.[2](#)

- [14] ペドロ・F・フェルゼンシュワルプ、ロス・B・ガーシック、デビッド・マカラスター、デヴァ・ラマナン。識別的に学習されたパーツベースモデルによる物体検出。*IEEE Transactions on Pattern Analysis and Machine Intelligence*, 32:1627-1645, 2010.[3](#)
- [15] Ian Goodfellow、Jean Pouget-Abadie、Mehdi Mirza、Bing Xu、David Warde-Farley、Sherjil Ozair、Aaron Courville、Yoshua Bengio。Generative adversarial networks.*Communications of the ACM*, 63(11):139-144, 2020.[3](#)
- [16] 郭桂、趙振、齊磊、周魯平、王磊、石英環。(注)本論文は、本論文の一部である。In *Advances in Neural Information Processing Systems*, 2022.[2](#), [3](#)
- [17] 李伟浩、洪潔、モハメド・アリ・アーミン、イアン・リード、ラース・ピーターソン、李宏東。(1)一度しかカットしない：一度のカットでデータ拡張をブーストする。*International Conference on Machine Learning*, 2022.[3](#), [6](#), [7](#), [8](#)
- [18] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun.Deep residual learning for image recognition.In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 770-778, 2016.[6](#)
- [19] ホン・ミヌイ、チェ・ジヌ、キム・ガンヒ。
Stylemix：Separating content and style for enhanced data augmentation.*IEEE/CVF Conference of the Computer Vision and Pattern Recognition*, pages 14862-14870, 2021.[3](#)
- [20] 姜華瑞、アシシュ・シン、アディティヤ・ブラサド、ディーブ・チャクラボルティ、エリック・ラーン・ド・ミラー。Unsupervised hard example mining from videos for improved object detection.*Proceedings of the European Conference on Computer Vision*, pages 307-324, 2018.[3](#)
- [21] Guoliang Kang, Xuanyi Dong, Liang Zheng, and Yi Yang.Patchshuffle regularization. *arXiv preprint arXiv:1707.07103*, 2017.[3](#)
- [22] Jonathan Krause, Michael Stark, Jia Deng, and Li Fei-Fei.3d object representations for fine-grained categorization.*IEEE International Conference on Computer Vision workshops*, pages 554-561, 2013.[3](#)
- [23] A.Krizhevsky and G. Hinton.極小画像からの多層特徴の学習。*Handbook of Systemic Autoimmune Diseases*, 1(4), 2009.[6](#)
- [24] Chia-Wen Kuo、Chih-Yao Ma、Jia-Bin Huang、Zsolt Kira。Featmatch：半教師あり学習のための特徴ベースの補強。*European Conference on Computer Vision*, pages 479-495, 2020.[2](#)
- [25] Samuli LaineとTimo Aila。半教師付き学習のための時間的アンサンブル。*International Conference on Learning Representations*, 2017.[2](#)
- [26] Junnan Li, Caiming Xiong, and Steven CH Hoi.Comatch：Comatch：対照的グラフ正則化を用いた半教師付き学習。*IEEE/CVF International Conference on Computer Vision*, 2021.[3](#), [6](#)
- [27] Sungbin Lim, Ildoo Kim, Taesup Kim, Chiheon Kim, and Sungwoong Kim.Fast autoaugment.*Advances in Neural Information Processing Systems*, 32, 2019.[3](#)
- [28] ジロン・リン、ヨン・シー、ジー・シュエ。Idsgan：Idsgan: Generative adversarial networks for attack generation against intrusion detection.In *Pacific-Asia Conference on Knowledge Discovery and Data Mining*, pages 79–91.Springer, 2022.[3](#)

- [29] イリヤ・ロシュチロフ、フランク・ハッター。ニューラルネットワークの高速訓練のためのオンラインバッチ選択。 *International Conference on Learning Representations Workshop*, 2015. [3](#)
- [30] 宮戸丈, 前田真一, 小山雅則, 石井伸. 仮想敵対学習: 教師あり学習と半教師あり学習のための正則化手法. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(8):1979-1993, 2018. [2](#)
- [31] Francisco J Moreno-Barea, Fiammetta Strazzer, Jose' M Jerez, Daniel Urda, Leonardo Franco. Forward noise adjustment scheme for data augmentation. In *2018 IEEE Symposium Series on Computational Intelligence (SSCI)*, pages 728-734. IEEE, 2018. [3](#)
- [32] Yuval Netzer, Tao Wang, Adam Coates, Bo Bissacco, Andrew Y Ng. を用いた自然画像中の数字の読み取り。 *NIPS Workshop on Deep Learning and Unsupervised Feature Learning*, 2011. [6](#)
- [33] 大津信行. 濃淡ヒストグラムからの閾値選択法. *IEEE Transactions on Systems, Man, and Cybernetics*, 9(1):62-66, 1979. [4](#)
- [34] Yassine Ouali, Céline Hudelot, and Myriam Tami. *ArXiv preprint arXiv:2006.05278*, 2020. [2](#)
- [35] (注1)本論文は、本論文の一部である。を用いた正則化。 *Advances in Neural Information Processing Systems*, 29, 2016. [2](#)
- [36] Connor Shorten, Taghi M Khoshgohar. ディープラーニングのための画像データ増強に関する調査。 *Journal of Big Data*, 6(1):1-48, 2019. [3](#)
- [37] Abhinav Shrivastava, Abhinav Gupta, and Ross Girshick. オンラインハードエクサンプルマイニングによる領域ベースのオブジェクト検出器のトレーニング。 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 761-769, 2016. [3](#)
- [38] Edgar Simo-Serra, Eduard Trulls, Luis Ferraz, Iasonas Kokkinos, and Francesc Moreno-Noguer. Fracking deep convolutional image descriptors. *arXiv preprint arXiv:1412.6537*, 2014. [3](#)
- [39] Kihyuk Sohn, David Berthelot, Chun-Liang Li, Zizhao Zhang, Nicholas Carlini, Alex Kurakin, Han Zhang, Colin Raffel. Fixmatch: (注1)本論文は、本論文の一部である。 *Advances in Neural Information Processing Systems*, 2020. [1](#), [3](#), [4](#), [6](#)
- [40] Jiawei Su, Danilo Vasconcellos Vargas, and Kouichi Sakurai. ディープニューラルネットワークを騙すための1ピクセル攻撃. *IEEE Transactions on Evolutionary Computation*, 23(5), 2019. [3](#)
- [41] Kai Sheng Tai, Peter Bailis, Gregory Valiant. シンクホーンのラベル割り当て: を用いた半教師付き分類. *Workshop on Challenges in Representation Learning, ICML*, 2021. [6](#)
- [42] アンティ・タルヴァイネン、ハッリ・ヴァルポラ。平均的な教師はより良いロールモデルである: Weight-averaged consistency targets improve semi-supervised deep learning results. *Advances in Neural Information Processing Systems*, 2017. [2](#), [6](#)
- [43] 所爪祐司、牛久義隆、原田達也. 画像分類のためのクラス間学習. In *Proceed-*

- ings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 5486-5494, 2018.[3](#)
- [44] Vikas Verma, Alex Lamb, Juho Kannala, Yoshua Bengio, and David Lopez-Paz. Interpolation consistency training for semi-supervised learning. In *International Joint Conference on Artificial Intelligence*, pages 3635-3641, 2019.[2](#)
- [45] Jianfeng Wang, Thomas Lukasiewicz, Daniela Massiceti, Xiaolin Hu, Vladimir Pavlovic, and Alexandros Neophytou. Np-match: 神経過程と半教師付き学習が
出会うとき。 In *International Conference on Machine Learning*, pages 22919-22934. PMLR, 2022.[6](#)
- [46] Xiaolong Wang と Abhinav Gupta. 動画を用いた視覚表現の教師なし学習。 *Proceedings of the IEEE International Conference on Computer Vision*, pages 2794-2802, 2015.[3](#)
- [47] Lingxi Xie, Jingdong Wang, Zhen Wei, Meng Wang, and Qi Tian. Disturblabel: 損失層で cnn を正則化する。 *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4753-4762, 2016.[3](#)
- [48] 李錫、雷尚、金星葉、錢齊、李玉鳳、孫白貴、李昊、金榮。 Dash: 動的閾値を用いた半教師付き学習。 In *Proceedings of the International Conference on Machine Learning*, 2021.[2](#), [3](#), [6](#)
- [49] ホン・シュアン、アビー・スタイリアヌー、シャオトン・リュウ、ロバート・プレス。 難しい否定例は難しいが有用である。 *European Conference on Computer Vision*, pages 126-142. シュプリンガー、2020年[3](#)
- [50] ユン・サンドウ、ハン・ドンユン、オ・ソンジュン、チョン・サンヒョク、チェ・ジュンソク、ユ・ヨンジュン。 Cutmix: 局所化可能な特徴を持つ強力な分類器を訓練するための正規化戦略。 *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 6023-6032, 2019.[3](#)
- [51] セルゲイ・ザゴルイコとニコス・コモダキス。 Wide residual networks. *Proceedings of the British Machine Vision Conference*, 2016.[6](#)
- [52] Bowen Zhang, Yidong Wang, Wenxin Hou, Hao Wu, Jindong Wang, Manabu Okumura, and Takahiro Shinozaki. Flexmatch: (1) 学習カリキュラムの擬似ラベリングによる半教師付き学習のブースト. *Advances in Neural Information Processing Systems*, 2021.[2](#), [3](#), [4](#), [6](#)
- [53] ホンイー・チャン、ムスタファ・シセ、ヤン・N・ドーフアン、ダヴィッド・ロペス＝パス。 ミックスアップ: Beyond empirical risk minimization. In *Fifth International Conference on Learning Representations*, 2017.[3](#)
- [54] 趙振、周魯平、段躍、王磊、齊磊、史穎煥。 Dc-ssl: 半教師付き学習におけるクラス分布の不一致への対処。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9757-9765, 2022.[2](#)
- [55] Mingkai Zheng, Shan You, Lang Huang, Fei Wang, Chen Qian, and Chang Xu. Simmatch: 類似マッチングによる半教師付き学習。 *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 14471-14481, 2022.[2](#), [3](#), [4](#), [6](#)
- [56] Zhun Zhong、Liang Zheng、Guoliang Kang、Shaozi Li、Yi Yang。 Random erasing data augmentation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 34, pages 13001-13008, 2020.[3](#)